Pré-processamento dos dados

Condição cardíaca de crianças e adolescentes

Grupo 3 · Antônio Henrique · João Vitor · Mateus Nery · Pedro Matos

INF0414 Mineração de Dados · Prof. Rogério Lopes Salvini · UFG · 2026/2

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

O caso e o que a A1 cobre

2 Seleção | **3 Limpeza** | **4 Transformação** | 5 Mineração | 6 Interpretação

Etapas 3 e 4 do KDD: a preparação de dados

12.873
atendimentos, 21 variáveis
Real Hospital Português, Recife

0 a 19 anos
crianças e adolescentes

Alvo
NORMAL X ANORMAL
(patologia cardíaca)

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Análise univariada: antes e depois da limpeza

Variável	Mediana	Desvio padrão	Mínimo – máximo
Altura (cm)	69 → 100	56,0 → 35,3	0 – 198 → 40 – 198
IDADE (anos)	3,96 → 3,86	8,83 → 4,51	−113 – 72 → 0 – 19,9
IMC (kg/m^2)	17,0 → 16,7	15,0 → 3,4	0 – 848 → 8,6 – 44,6
FC (bpm)	92 → 92	92,7 → 18,0	8 – 9.288 → 43 – 214

Antes: altura zero, idade negativa e FC de 9.288 bpm. Depois: todos os valores são possíveis.

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Problemas e soluções: ausentes e duplicados

Problema	Exemplo	Solução
Ausente escrito como valor	Altura = 0 (4.460); "Indeterminado"; "#VALUE!"	Vira ausente
Mais de 50% ausente	HDA2: 96,8%	Atributo excluído
Mais de 50% ausente	PA: 60%	Mantida para calcular a PPA
Objetos duplicados	987 iguais, menos no ID	Fica um de cada
Alvo sem rótulo	1.169 (417 depois dos duplicados)	Excluídos

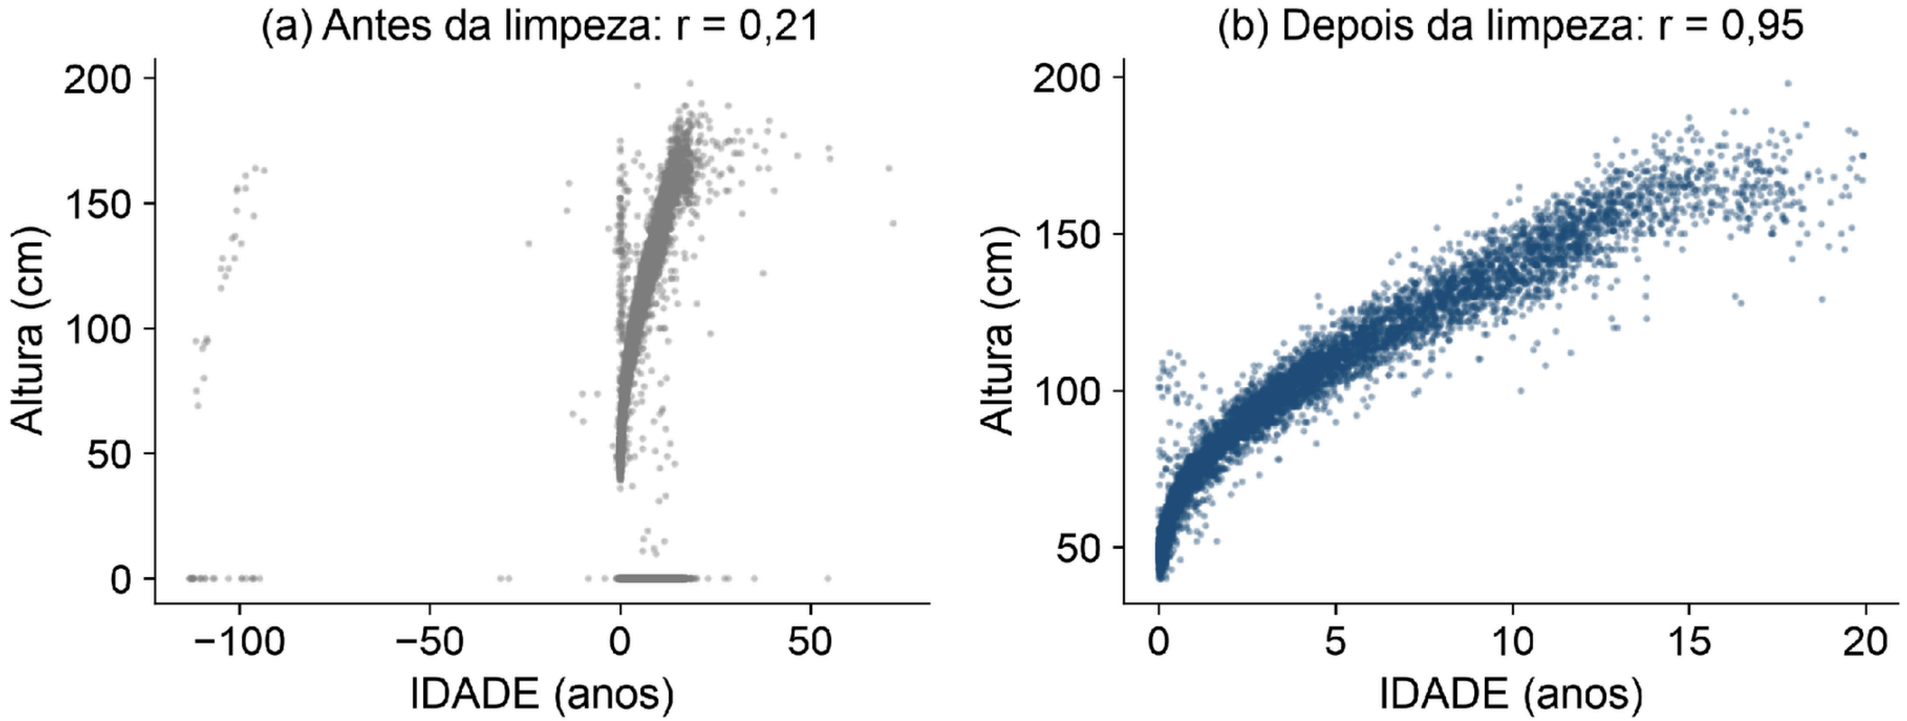
UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Problemas e soluções: inconsistências e ruído

Problema	Exemplo	Solução
Inconsistência léxica	SEXO: "M", "Masculino", "masculino"...	Padronizado: M e F
Inconsistência de domínio	IDADE de −113 anos	Vira ausente
Inconsistência lógica	Bebê com mais de 1,5 m	O valor errado vira ausente
Inconsistência temporal	Nasceu depois do atendimento	Vira ausente
Ruído	FC de 9.288 bpm	Vira ausente
Atributo repetido	PULSOS: 98,7% "Normais"	Mantido

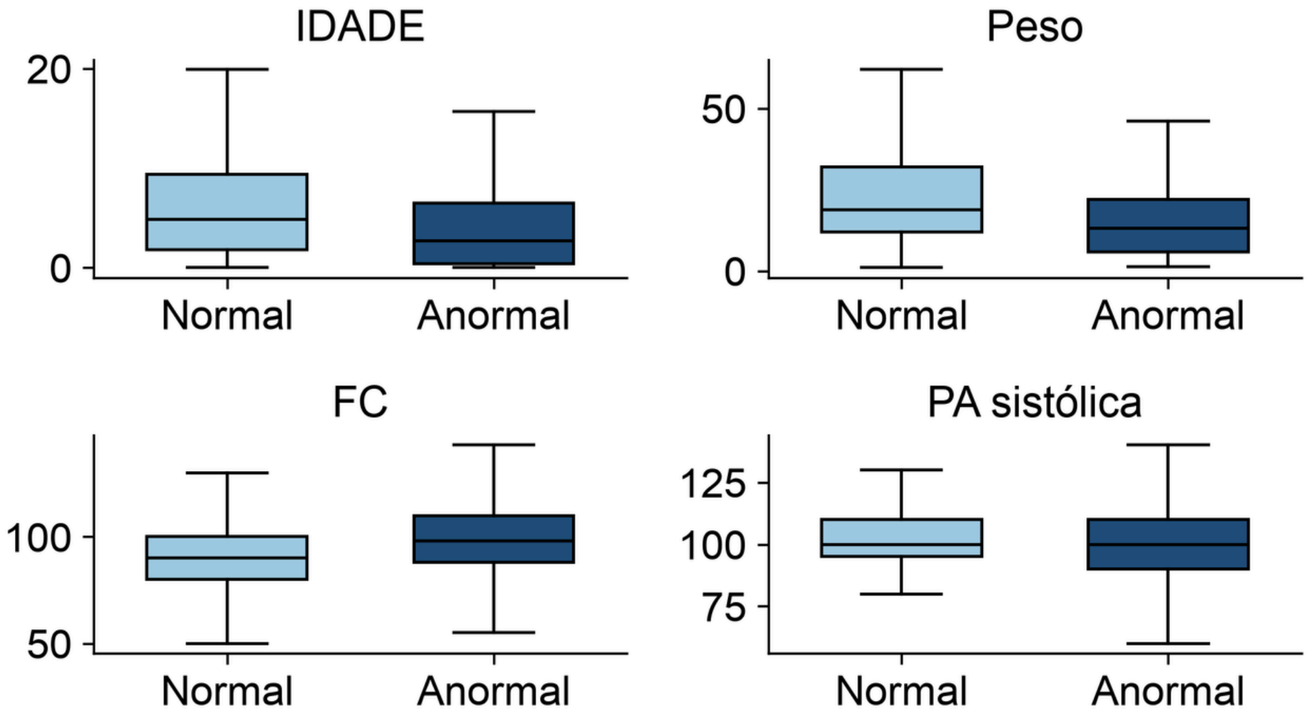
UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Duas variáveis depois da limpeza: Altura e IDADE



UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Bivariada: numéricas × alvo



Idade

Mediana de 2,69 anos nos anormais e 4,85 nos normais

PA sistólica

Sem diferença entre as classes (p = 0,60)

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Bivariada: categóricas × alvo

Variável	Menor % de anormais	Maior % de anormais
SOPRO	Ausente: 10,1%	Sistólico: 95,9%
B2	Normal: 39,9%	Hiperfonética: 97,9%
PULSOS	Normais: 42,1%	Femorais diminuídos: 92,1%
MOTIVO1	Parecer: 25,7%	Cardiopatia estabelecida: 71,3%
SEXO	M: 41,3%	F: 43,1% (sem associação)

Tabela de contingência e teste qui-quadrado (aula 03); categorias com 30 ou mais atendimentos

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Transformações: redução de dados

Eliminação de atributos

ID e Convenio

Sem relação com o diagnóstico. É o exemplo da aula: "ID ou Plano de Saúde".

Datas e pressões

Já deram a IDADE e a PPA. As pressões têm mais de 50% de ausentes.

IMC

IMC = Peso / Altura^2. Exemplo da aula: para prever doença, manter Peso e Altura.

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Transformação de atributos e criação

Técnica	Atributos	Por quê
One-Hot Encoding	PULSOS, B2, SOPRO, HDA 1, MOTIVO1, MOTIVO2	Nominais, sem ordem
Recalcular + One-Hot	PPA	"Desconhecido" não tem lugar na ordem
Discretização + Ordinal	IDADE em 4 faixas	Anormais caem de 61,2% para 29,0%
log + Z-score	log em Peso e FC; Z-score em Peso, Altura e FC	Assimetria e escalas diferentes
Binary e Label Encoding	SEXO (M, F e Desconhecido: 2 colunas); alvo: Normal = 0, Anormal = 1	Menos colunas que One-Hot; variável dependente

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Balanceamento e a regra do treino

42,7%

de anormais: as classes já estão próximas (1,34 : 1), sem balanceamento

Importante (aula 05)

Tudo que aprende com os dados é ajustado só no conjunto de treinamento e depois aplicado ao teste.

UFG
UNIVERSIDADE FEDERAL DE GOIÁS

Duvidas?

UFG
UNIVERSIDADE
FEDERAL DE GOIÁS