Pré-processamento dos dados do estudo de caso: condição cardíaca de crianças e adolescentes

Grupo 3 — Antônio Henrique Queiroz Villar Lopes · João Vitor Fernandes Ferreira · Mateus Nery Bailão · Pedro Augusto Ferreira Matos

INF0414 Mineração de Dados · Prof. Rogério Lopes Salvini · UFG · 2026/2

1. Introdução

A base UCMF tem 12.873 atendimentos e 21 variáveis de crianças e jovens de 0 a 19 anos (Real Hospital Português, Recife-PE). O alvo é NORMAL X ANORMAL (presença de patologia cardíaca). O relatório cobre as etapas 3 (limpeza) e 4 (transformação) do KDD, na ordem: análise descritiva, problemas de qualidade, limpeza e nova descrição para comparar antes e depois.

2. Análise univariada

Tipos e escalas (aula 02). Peso, Altura, IMC e IDADE: numéricas contínuas (razão). PA SISTOLICA, PA DIASTOLICA e FC: numéricas discretas (razão). Atendimento e DN: numéricas intervalares. PPA: categórica ordinal. ID e as demais: categóricas nominais (SEXO e NORMAL X ANORMAL, binárias).

A Tabela 1 traz localização, dispersão e forma (aula 03) das numéricas. "Antes" é o arquivo lido (12.873 linhas); "Depois", a base limpa da Seção 3 (11.469 linhas). DP = desvio padrão; IQR = Q3 − Q1. Unidades: kg, cm, kg/m², anos, mmHg e bpm.

Tabela 1 — Variáveis numéricas antes e depois da limpeza

Variável	Estado	n	Média	Mediana	DP	IQR	Mín.	Máx.	Assimetria
Peso	Antes	12.555	16,61	12,80	16,98	20,60	−40,00	157,00	1,46
	Depois	9.472	20,74	16,00	16,23	19,00	1,00	101,00	1,39
Altura	Antes	12.873	66,11	69,00	56,03	112,00	0,00	198,00	0,11
	Depois	7.956	100,95	100,00	35,28	58,00	40,00	198,00	0,19
IMC	Antes	8.146	17,46	17,00	15,01	4,00	0,00	848,00	43,19
	Depois	7.565	17,29	16,71	3,39	3,75	8,60	44,62	1,36
IDADE	Antes	11.377	4,86	3,96	8,83	7,66	−113,18	71,81	−7,83
	Depois	10.735	5,04	3,86	4,51	7,24	0,00	19,91	0,77
PA SISTOLICA	Antes	5.143	101,80	100,00	18,90	20,00	60,00	990,00	26,61
	Depois	5.099	101,50	100,00	11,58	20,00	60,00	180,00	1,19
PA DIASTOLICA	Antes	5.133	62,65	60,00	9,09	10,00	6,00	120,00	0,92
	Depois	5.089	62,66	60,00	9,03	10,00	35,00	120,00	0,97
FC	Antes	10.989	96,64	92,00	92,71	20,00	8,00	9.288,00	89,48
	Depois	10.760	95,17	92,00	17,96	20,00	43,00	214,00	1,16

Antes: peso negativo, altura zero, IMC de 848, idade de −113 anos e FC de 9.288 bpm. Depois, todos os valores são possíveis, o DP cai em todas as variáveis e a assimetria cai onde havia valores absurdos.

Tabela 2 — Variáveis categóricas antes e depois da limpeza

Variável	Grafias antes → categorias depois	% vazio antes	% ausente depois	Frequência relativa depois (% dos válidos, 3 maiores)
SEXO	6 → 2	0,0	4,6	M 59,0 · F 41,0
Convenio	374 → 253	31,9	27,5	GS 23,9 · UR 16,7 · CAMED 6,4
PULSOS	7 → 5	9,3	0,3	Normais 98,7 · Amplos 0,5 · Femorais diminuídos 0,3
PPA	9 → 7	1,7	81,9	Normal 86,1 · HAS-2 PAS 3,5 · Pré-hipertensão PAD 3,5
NORMAL X ANORMAL	4 → 2	9,1	0,0	Normal 57,3 · Anormal 42,7
B2	5 → 5	9,2	0,2	Normal 94,9 · Hiperfonética 2,5 · Desdob. fixo 1,3
SOPRO	7 → 5	9,1	0,1	Ausente 61,9 · Sistólico 37,6 · Contínuo 0,4
HDA 1	8 → 8	33,2	25,9	Assintomático 76,2 · Dispneia 6,3 · Dor precordial 5,9
HDA2	8 → excluída	96,8	—	Antes: Dispneia 20,4 · Palpitação 20,4 · Dor precordial 16,0
MOTIVO1	5 → 5	8,2	1,2	Parecer 45,5 · Suspeita de cardiopatia 36,1 · Cardiopatia estabelecida 9,8
MOTIVO2	16 → 16	27,2	22,1	Cirurgia 31,8 · Sopro 25,2 · Cardiopatia congênita 11,2

A queda de ausentes em PULSOS, B2, SOPRO e MOTIVO1 vem da exclusão dos duplicados (em sua maioria linhas vazias) e dos atendimentos sem rótulo; não houve preenchimento. O ID tem 12.873 valores distintos e nenhum vazio. Na base limpa, Atendimento vai de 13/01/2003 a 14/11/2010 (mediana em 26/06/2007) e DN de 25/05/1983 a 12/04/2010 (mediana em 17/01/2003).

3. Problemas de qualidade e soluções de limpeza

Classificação da aula 04: ausentes, duplicados, repetidos, inconsistentes (léxica, lógica, de domínio, temporal) e atípicos (ruído e outlier). Limites de plausibilidade definidos pelo grupo: Peso 1–150 kg, Altura 40–200 cm, IDADE 0–19 anos (< 20), IMC 8–60 kg/m², FC 40–220 bpm, PAS 50–200 mmHg e PAD 30–130 mmHg. Fora do limite, é inconsistência de domínio se viola a realidade (peso negativo) e ruído se é erro de medida ou digitação (FC de 9.288 bpm); nos dois casos o valor vira ausente, sem apagar o atendimento. Outliers possíveis foram mantidos, salvo se não combinam com a idade. A Tabela 3 resume, por variável, o problema e a solução aplicada.

Inconsistência lógica (exemplo da aula 04: criança de 2 anos com 80 kg). Peso e Altura são comparados aos das crianças da mesma idade em anos; fora de Q1 − 3·IQR a Q3 + 3·IQR, o valor não combina com a idade. Se só um não combina, ele vira ausente; se os dois não combinam (mas combinam entre si), o erro está na IDADE, que vira ausente.

Tabela 3 — Problemas encontrados e soluções aplicadas

Variável	Problema (tipo)	Solução
Todas	Objetos duplicados: 987 registros iguais a outro em tudo, menos no ID (a maioria, linhas vazias)	Fica um de cada; os demais saem
ID	Nenhum	—
Peso	Ausentes: 318 vazios e 2.609 zeros. Domínio: 4 fora de 1 a 150 kg (ex.: −40). Lógica: 34 pesos que não combinam com a idade	Todos → ausente
Altura	Ausentes: 4.460 zeros (a contagem de vazios dá 0%; o real é 34,6%). Domínio: 12 fora de 40 a 200 cm. Lógica: 48 que não combinam com a idade	Todos → ausente
IMC	Ausentes: 4.727 vazios e 109 zeros. Domínio: máximo de 848 kg/m²	Recalculado a partir de Peso e Altura (aula 04); fora de 8 a 60 → ausente
Atendimento	Ausentes: 983. Léxica: formatos diferentes e 312 datas gravadas como número da planilha. Temporal: 25 fora de 2003 a 2010, os anos de 99,8% dos atendimentos (ex.: 2066)	Formatos padronizados. Fora de 2003 a 2010 → ausente
DN	Ausentes: 1.376 vazios e 2 "???". Léxica: 124 datas como número da planilha. Ruído: 80 mal digitadas (ex.: "01/011/05") e 19 ilegíveis. Temporal: 70 nascimentos depois do atendimento	Padronizadas; digitação corrigida; idade escrita no lugar da data (19, ex.: "3a") → IDADE. Ilegíveis e posteriores ao atendimento → ausente
IDADE	Ausentes: 1.496. Domínio: 202 fora de 0 a 19 anos (122 negativas, 80 de 20 ou mais). Lógica: 56 que não combinam com Peso e Altura	Recalculada de Atendimento e DN. As 70 ainda fora de 0 a 19 e as 56 da lógica → ausente
SEXO	Léxica: 5 grafias (M, Masculino, masculino, F, Feminino). Ausentes: 1.417 "Indeterminado"	Padronizado em M e F; "Indeterminado" → ausente
Convenio	Ausentes: 31,9%. Léxica: 374 grafias (ex.: "NORCLIN.", "Norclínicas")	Caixa e acento padronizados (restam 253); siglas não unidas, pois o atributo é eliminado
PULSOS	Ausentes: 9,3%. Léxica: 7 grafias para 5 categorias. Repetido: 98,7% "Normais"	Padronizado. Mantido (regra dos 50%, abaixo)
PA SISTOLICA	Ausentes: 60,0%. Ruído: 2 fora de 50 a 200 mmHg (ex.: 990)	Ruído → ausente. Mantida (regra dos 50%, abaixo)
PA DIASTOLICA	Ausentes: 60,1%. Ruído: 2 fora de 30 a 130 mmHg (ex.: 6)	Mesma solução da PA SISTOLICA
PPA	Ausentes: 217 vazios, 9.081 "Não Calculado" e 1.496 "#VALUE!" (erro de fórmula). Repetido: 86,1% "Normal"	Viram ausente; recalculada na transformação. Mantida (regra dos 50%)
NORMAL X ANORMAL	Léxica: 3 grafias (Normal, Anormal, anormal). Domínio: 1 "Normais", de PULSOS. Ausentes: 1.168	Padronizado; "Normais" → ausente. Sem rótulo → atendimento excluído (o alvo não é imputado)
B2	Ausentes: 9,2%. Repetido: 94,9% "Normal"	Mantido (regra dos 50%, abaixo)

Variável	Problema (tipo)	Solução
SOPRO	Ausentes: 9,1%. Léxica: 7 grafias para 5 categorias. Repetido: 61,9% "Ausente"	Padronizado. Mantido (regra dos 50%, abaixo)
FC	Ausentes: 14,5%. Léxica: 16 escritos como faixa (ex.: "170-150"). Ruído: 17 fora de 40 a 220 bpm (ex.: 9.288)	Faixa → ponto médio. Ruído → ausente
HDA 1	Ausentes: 33,2%. Repetido: 76,2% "Assintomático"	Mantido (regra dos 50%, abaixo)
HDA2	Ausentes: 96,8%	Atributo excluído (regra dos 50%)
MOTIVO1	Ausentes: 8,2%	Mantido
MOTIVO2	Ausentes: 27,2%	Mantido

Regra dos 50% (aula 04: "esse limite varia"). Ausentes: a HDA2 (96,8%) é excluída. PAS e PAD ficam até recalcularmos a PPA, e a PPA fica por ser o único atributo sobre hipertensão, apesar dos 81,9% de ausentes (exceção tratada na Seção 6). As datas ficam só para calcular a IDADE. Repetidos: PULSOS, B2, PPA, HDA 1, SOPRO e SEXO passam de 50% na categoria mais frequente, mas ficam: nas categorias raras o % de anormais muda muito (ex.: "Femorais diminuídos", em PULSOS, tem 92,1% de anormais contra 42,1% nos "Normais"); o SEXO (59,0%) é binário e necessário à PPA. Ausentes que continuam: nas categóricas viram "Desconhecido"; nas numéricas, são preenchidos pela mediana da faixa etária, calculada só no treino (Seção 6). Contagem final: 12.873 − 987 duplicados − 417 sem rótulo = 11.469 (os outros 752 sem rótulo estavam entre os duplicados).

4. Comparação de duas variáveis após a limpeza

Escolhemos Altura e IDADE porque a limpeza mudou muito as duas (4.460 alturas zero e idades negativas) e porque a criança cresce com a idade. Pela Tabela 1, a mediana da Altura vai de 69 para 100 cm e a faixa da IDADE, de −113 a 72 para 0 a 19 anos.

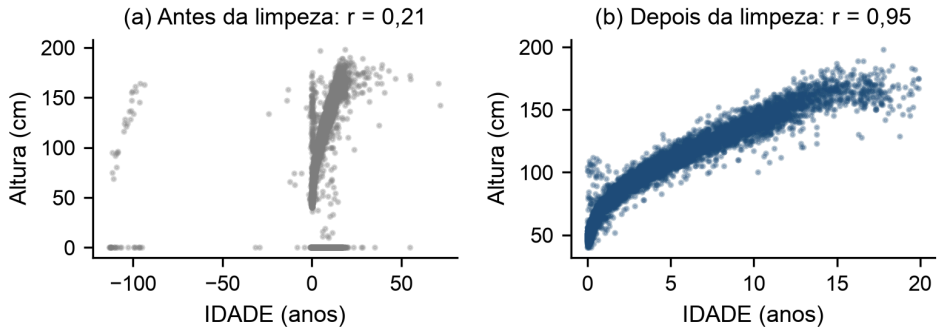


Figura 1 — *Altura × IDADE antes (a) e depois (b) da limpeza, com a correlação de Pearson (r).*

Interpretação (Figura 1). Em (a), os pontos em Altura = 0 são zeros que representavam ausência e os da esquerda são idades negativas; como o Pearson é sensível a outliers (aula 03), r = 0,21 (desprezível). Em (b), os pontos formam a curva de crescimento esperada (rápida nos primeiros anos, mais lenta na adolescência) e r = 0,95 (muito forte); o Spearman, indicado para relação não linear, confirma (0,38 e 0,98). A diferença vem da limpeza.

5. Análise bivariada com a variável-alvo

Cada variável independente foi cruzada com o alvo (aula 03). Numéricas: boxplot (Figura 2), mediana por classe e teste t de Student. Categóricas: tabela de contingência (% de anormais por categoria) e qui-quadrado, agregando em "Outros" as categorias com menos de 30 atendimentos. Na Tabela 4, a coluna Comparação traz a mediana normais × anormais (numéricas) ou o % de anormais nas categorias com menos e com mais anormais (categóricas, sem "Outros"). ID, Atendimento e DN ficam de fora (código e datas usadas só na IDADE) e a HDA2 foi excluída. Na base limpa, 42,7% são anormais.

Tabela 4 — Cada variável independente contra o alvo

Variável	Comparação	p (teste t ou χ^2)	Leitura
IDADE (anos)	4,85 × 2,69	< 0,001	Os anormais são mais novos
Peso (kg)	18,70 × 13,00	< 0,001	Mais leves (são mais novos)
Altura (cm)	107 × 90	< 0,001	Mais baixos (são mais novos)
IMC (kg/m²)	17,08 × 16,26	< 0,001	Diferença pequena
FC (bpm)	90 × 98	< 0,001	FC mais alta nos anormais
PA SISTOLICA	100 × 100	0,599	Sem diferença
PA DIASTOLICA	60 × 60	0,044	Médias quase iguais (62,85 × 62,32)
SOPRO	Ausente 10,1 × Sistólico 95,9	< 0,001	A mais associada ao alvo

Variável	Comparação	p (teste t ou χ^2)	Leitura
B2	Normal 39,9 × Hiperfonética 97,9	< 0,001	B2 alterado: quase sempre anormal
PULSOS	Normais 42,1 × Femorais diminuídos 92,1	< 0,001	Categoria rara e muito associada
MOTIVO1	Parecer 25,7 × Cardiopatia estabelecida 71,3	< 0,001	O motivo do encaminhamento já indica o laudo
MOTIVO2	Cirurgia 23,2 × Sopro 76,2	< 0,001	Idem
HDA 1	Desmaio/tontura 29,2 × Cianose 55,1	< 0,001	Cianose e dispneia têm mais anormais
PPA	Pré-hipertensão PAS 33,3 × HAS-2 PAS 56,2	0,009	Só HAS-2 PAS passa da média de 42,7% (82% ausentes)
Convenio	NORCLINICA 27,8 × SUS 95,5	< 0,001	Mostra de onde vem o paciente, não a doença
SEXO	M 41,3 × F 43,1	0,062	Sem associação

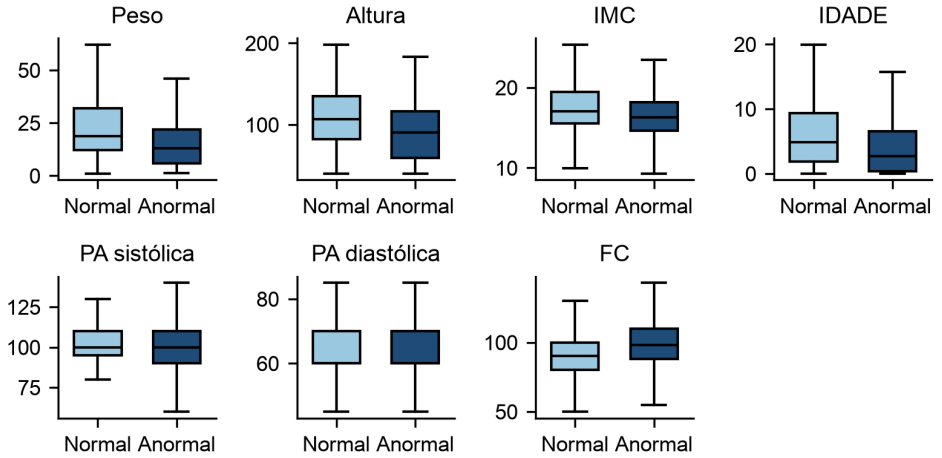


Figura 2 — *Boxplot de cada variável numérica por classe (sem os pontos atípicos, para facilitar a leitura).*

Interpretação. O SOPRO é a variável mais associada ao alvo: 95,9% dos atendimentos com sopro sistólico são anormais, contra 10,1% dos sem sopro. B2, PULSOS e os motivos do encaminhamento vêm em seguida. Entre as numéricas, a diferença mais clara é a idade: os anormais são mais novos e, por isso, também menores e mais leves (Figura 2). As pressões quase não mudam entre as classes, e o SEXO não tem associação com o alvo. Com milhares de atendimentos, o p pode ser pequeno mesmo com diferença mínima (PA DIASTOLICA: 62,85 × 62,32), então lemos o p junto com o tamanho da diferença.

6. Transformações previstas e justificativa

Seguimos os quatro blocos das aulas de transformação (atributos, criação, redução e balanceamento). Tudo que aprende algo dos dados (mediana, média, desvio padrão, categorias) é ajustado só no conjunto de treinamento e depois aplicado ao teste (aula 05). A Tabela 5 lista as transformações e o porquê de cada uma.

Tabela 5 — Transformações a realizar

Atributo	Transformação (bloco)	Por quê
ID, Convenio	Eliminação manual de atributos (redução)	Sem relação com o diagnóstico; é o exemplo da aula ("ID ou Plano de Saúde"). No SUS, 95,5% são anormais: o modelo aprenderia a origem do paciente
Atendimento, DN	Eliminação de atributos redundantes (redução)	A IDADE é derivada delas e continua na base
PA SISTOLICA, PA DIASTOLICA	Eliminação de atributos redundantes (redução), depois de recalcular a PPA	Mais de 50% de ausentes; a informação delas passa para a PPA, como a das datas para a IDADE
IMC	Eliminação de atributo derivado (redução)	IMC = Peso / Altura². É o exemplo da aula: para prever doença, manter Peso e Altura e eliminar o IMC

Atributo	Transformação (bloco)	Por quê
PPA	Recalcular (criação: construção de atributo) e One-Hot Encoding	Vem de PAS, PAD, idade, sexo e altura (tabelas de pressão do material complementar); recalcular recupera parte dos casos em que a fórmula falhou. Fica mesmo com 81,9% de ausentes por ser o único atributo sobre hipertensão. One-Hot, e não Ordinal, porque "Desconhecido" não tem lugar na ordem Normal < Pré-hipertensão < HAS-1 < HAS-2
IDADE	Discretização em faixas definidas pelo usuário (menos de 1 ano, 1 a 5, 6 a 9 e 10 a 19 anos) e Ordinal Encoding (0 a 3)	O percentual de anormais cai em degraus: 61,2%, 39,9%, 35,3% e 29,0%; as faixas têm ordem
Peso, Altura, FC (ausentes)	Imputação pela mediana da faixa etária (as 4 faixas da IDADE), ajustada só no treino	Altura e IDADE têm r = 0,95 (Seção 4): a mediana geral daria 100 cm a um bebê. Sem IDADE, usa-se a mediana geral
Peso, Altura, FC	Log em Peso e FC; depois Padronização Z-score nos três	Peso e FC são assimétricas (1,39 e 1,16); o log aproxima da distribuição normal (−0,29 e 0,52). Escalas diferentes (kg, cm, bpm): o Z-score evita que um atributo domine outro e lida melhor com outliers que o Min-Max
SEXO	Binary Encoding	Com M, F e "Desconhecido" (3 categorias), usa 2 colunas
PULSOS, B2, SOPRO, HDA 1, MOTIVO1, MOTIVO2	One-Hot Encoding	São nominais, sem ordem, e têm poucas categorias (de 5 a 16). MOTIVO1 e MOTIVO2 já indicam o laudo: risco de vazamento, a avaliar na modelagem
NORMAL X ANORMAL	Label Encoding (Normal = 0, Anormal = 1)	É a variável dependente
Classes	Sem balanceamento	São 42,7% de anormais contra 57,3% de normais (1,34 : 1); as classes já estão próximas

7. Uso de inteligência artificial generativa

Qual: Claude (Anthropic). Onde e para quê: scripts Python de limpeza, estatísticas e figuras; extração das tabelas de pressão dos PDFs; redação e revisão do relatório e dos slides. Como: por conversa, uma tarefa por vez, conferindo os números ao rodar os scripts sobre o arquivo original. As decisões de limpeza e transformação foram do grupo.

Referências. Slides das aulas de Mineração de Dados (Prof. Rogério Salvini, 2026): fundamentos, dados, exploração, limpeza, transformação de atributos, criação e redução de dados. Material complementar do estudo de caso (tabelas de pressão arterial para crianças e explicação da variável PPA).