A2 - Processo completo do KDD

Mineração de Dados - UFG - Grupo 3 - 04/11/2026

Antônio Henrique Queiroz Villar Lopes, João Vitor Fernandes Ferreira, Mateus Nery Bailão e Pedro Augusto Ferreira Matos

1. Objetivo e conhecimento procurado

O estudo procura padrões que distinguem Normal de Anormal no rótulo registrado da base UCMF. A tarefa é classificação supervisionada: há exemplos com uma resposta binária disponível. Não se presume um diagnóstico independente nem se anuncia capacidade de triagem antes do exame. Agrupamento, regressão e associação seriam outras tarefas; não substituem essa pergunta.

A A2 reúne o processo inteiro do KDD. Reutilizamos a A1 como ponto de partida, criticamos e melhoramos sua preparação, executamos mineração, avaliação, interpretação e uma aplicação acadêmica. A A1 avaliada continua sendo a versão já entregue; os documentos históricos permanecem idênticos. A descrição formal da A2 ainda poderá acrescentar exigências de apresentação, sem tornar pendente o processo técnico executado aqui.

2. Seleção, população e entendimento dos dados

A entrada possui 12.873 linhas e 21 variáveis. Conservamos todas as linhas, inclusive equivalências candidatas e registros sem alvo. Normal=0 e Anormal=1; são 6.744 Normais, 4.960 Anormais e 1.169 sem rótulo utilizável. A classificação usa apenas os 11.704 conhecidos antes da quarentena. Não imputamos y. ID único não estabelece paciente único.

A preparação mantém 9.361 registros de desenvolvimento, 2.342 no teste histórico e uma quarentena anterior ao ajuste. A união transitiva dos grupos exigiu 0 quarentenas adicionais. Modelos dos cenários usam os mesmos registros e partições. As equivalências são candidatas; a dependência real entre atendimentos pode continuar maior que a identificada.

Papel	Variáveis
Medidas quantitativas	Peso, Altura, IMC, IDADE, PAS, PAD, FC
Nominais de exame/contexto	PULSOS, PPA, B2, SOPRO, HDA1, HDA2, SEXO, MOTIVO1, MOTIVO2
Rastreio e fonte de derivação	ID, Atendimento, DN
Administrativa fora de X	Convenio
Alvo separado de X	NORMAL X ANORMAL

3. Exploração e crítica da qualidade

Exploramos tipos, escalas, cobertura, tendência central, dispersão, forma das distribuições, correlação e associações bivariadas. Essas estatísticas usam medidas disponíveis antes da imputação. Faltante, zero-sentinela, inconsistência e outlier têm significados distintos; reduzir desvio ou aumentar correlação não prova que uma limpeza ficou correta.

A idade recebida acompanha dias/352 a até 0,01 ano em 11.191 casos comparáveis, com 11.120 coincidências exatas após arredondamento. Isso sustenta a crítica aritmética, sem revelar a fórmula original. A revisão resolve 11.208 idades relativas por pares de datas compatíveis sob o recorte pediátrico, sem escolher século absoluto. Dezoito idades literais são aproveitadas e 1.647 permanecem indisponíveis.

Medida	Disponíveis	Ausentes %	Mediana	DP
Peso	9.929	22,9	16,0	16,4
Altura	8.395	34,8	100,0	35,4
IMC	8.023	37,7	16,7	3,8

Medida	Disponíveis	Ausentes %	Mediana	DP
IDADE	11.226	12,8	3,9	4,5
PA SISTOLICA	5.140	60,1	100,0	11,6
PA DIASTOLICA	5.132	60,1	60,0	9,1
FC	10.995	14,6	92,0	18,2

4. Limpeza e criação de atributos: decisão por evidência

Padronizamos Unicode, espaços e grafias documentadas. Sentinelas são específicas da coluna: SOPRO Ausente é achado registrado e não campo vazio. Prefixos de MOTIVO2 não substituem a descrição completa. Alvos duvidosos não são inferidos. Datas exigem interpretação completa da célula; texto residual e ano ambíguo não são descartados para fabricar certeza.

A idade relativa usa aniversários de calendário e pares candidatos com 0 <= idade <20, tolerando até um dia de divergência na duração e guardando intervalo e hipótese. IMC = Peso/(Altura/100)^2 usa apenas pais observados operacionalmente utilizáveis; quando necessário, o valor histórico permanece com origem. Não recalculamos IMC depois de imputar seus pais.

Envelopes históricos são alertas. Preservamos pesos acima do antigo teto e frequências cardíacas positivas potencialmente reais. A guarda conjunta de razão antropométrica fora de 5-100 mascara o trio na política principal, sem escolher o campo errado ou apagar idade. Essa guarda e os demais cortes restantes são hipóteses de curadoria, não faixas clínicas. Foram mascarados 16 valores de Peso, 18 de Altura, 14 de IMC, 3 de PAS, 1 de PAD e 8 de FC. Uma alternativa com suspeitos preservados foi efetivamente testada.

O registro completo descreve as 21 variáveis, os formatos aceitos, sentinelas, condições, exceções, alternativas e incertezas. Valores brutos, candidatos e intervenções por célula ficam na proveniência local. Isso permite revisar uma decisão sem apagar a fonte.

5. Transformações e prevenção de vazamento

Comparamos medianas global, por idade e por idade/sexo por mascaramento artificial de 20% de medidas observadas, em cinco repetições apenas no desenvolvimento. Faixas fixas [0;0,25;0,5;1;2;5;10;15;20) precisam de 30 observados e têm fallback global. O diagnóstico favoreceu idade para Peso, Altura, FC e IMC; o IMC foi limítrofe. Isso não identifica o mecanismo das ausências reais.

Na mineração, a imputação global e a condicional por idade voltam a competir dentro de cada treino de fold. Assim, a escolha exploratória anterior não é tratada como um parâmetro já validado. Vocabulários, medianas, médias e desvios também são ajustados em cada treino. A matriz pronta de desenvolvimento não foi usada para selecionar modelos.

Categorias nominais usam one-hot, com estados separados para ausência e categoria inédita. Sete indicadores distinguem imputação de medida disponível. Z-score usa média e DP do treino (ddof=0); log1p é alternativa somente para Peso antes de padronizar. Bits continuam 0/1. Árvores usam unidades originais; logística compara a versão padronizada e a de log-Peso. A representação completa exportada possui 93 colunas, mas o vocabulário de cada fold pertence ao seu próprio treino.

6. Protocolo experimental e alternativas executadas

Cenário A inclui medidas, contexto e achados. B restringe-se às sete medidas e SEXO. B_contexto retira PULSOS, B2 e SOPRO de A, mantendo contexto cuja temporalidade não foi confirmada. São perguntas de disponibilidade diferentes: A não se anuncia como triagem antes do exame.

Comparamos 81 configurações em cada cenário por cinco folds estratificados e agrupados no desenvolvimento (seed 43). O critério é a média da acurácia balanceada; empates até 1e-12 seguem a ordem publicada. Sem custos confirmados de FP e FN, esse critério considera o recall das duas classes, enquanto precisão, recall e demais métricas continuam visíveis. Não é uma função de utilidade clínica.

A avaliação aninhada usa três folds externos e três internos, só no desenvolvimento (seeds 52 e 53+fold). A busca inteira se repete em cada treino externo. O resultado estima o procedimento de escolha condicionado às decisões de preparação já exploradas; não desfaz a exploração global anterior. Depois, todas as configurações finais são congeladas antes das métricas do teste histórico.

Família	Configurações	Alternativas principais
Controle majoritário	1	Referência sem informação de X
Árvore de decisão	40	Gini/entropia, profundidade3/6, folha20/50, poda alfa0,001/0,005, pesos e imputação
Regressão logística	32	C0,01/0,1/1/10, pesos, duas imputações e duas representações
Floresta aleatória	8	150 árvores, profundidade 8/None, folha10, pesos e imputação

7. Resultados atuais e significado da avaliação

Na busca principal, A escolheu árvore rasa com mediana global; B escolheu floresta de profundidade 8 com mediana global; B_contexto escolheu floresta com folha mínima 10 e mediana etária. O ganho de reconstrução da imputação etária não assegurou maior classificação. A teve muitas configurações empatadas em BA; a ordem publicada preferiu a árvore simples. A avaliação externa também escolheu logística em alguns folds de A e B_contexto, mostrando que o vencedor não é estável em todo subconjunto.

CV é a média dos folds usada na seleção. Nested é a acurácia balanceada das predições externas reunidas de modelos escolhidos dentro de cada treino externo. Teste é a avaliação secundária do conjunto histórico previamente explorado. Essas colunas não medem exatamente a mesma coisa; diferenças não demonstram melhora causal da limpeza nem desempenho em população nova.

Cenário	Modelo	CV BA	Nested BA	Teste BA	Recall	Precisão	AP	Brier
A	Árvore	0,919	0,919	0,929	0,888	0,957	0,934	0,057
B	Floresta	0,634	0,631	0,652	0,618	0,592	0,637	0,220
B_contexto	Floresta	0,713	0,710	0,742	0,679	0,718	0,759	0,179

7.1 Desempenho de ajuste e complexidade

O desempenho no próprio desenvolvimento usado para ajuste é descritivo e tende a ser otimista. A diferença para CV ajuda a investigar sobreajuste; não substitui validação. A busca aninhada escolheu configurações distintas entre folds, portanto a tabela não estabelece um vencedor universal. Os componentes candidatos incluem 1 grupos de desenvolvimento com rótulos mistos; não corrigimos automaticamente esses rótulos.

Cenário	BA no próprio treino	BA média CV	Atributos codificados
A	0,919	0,919	93
B	0,663	0,634	18
B_contexto	0,753	0,713	72

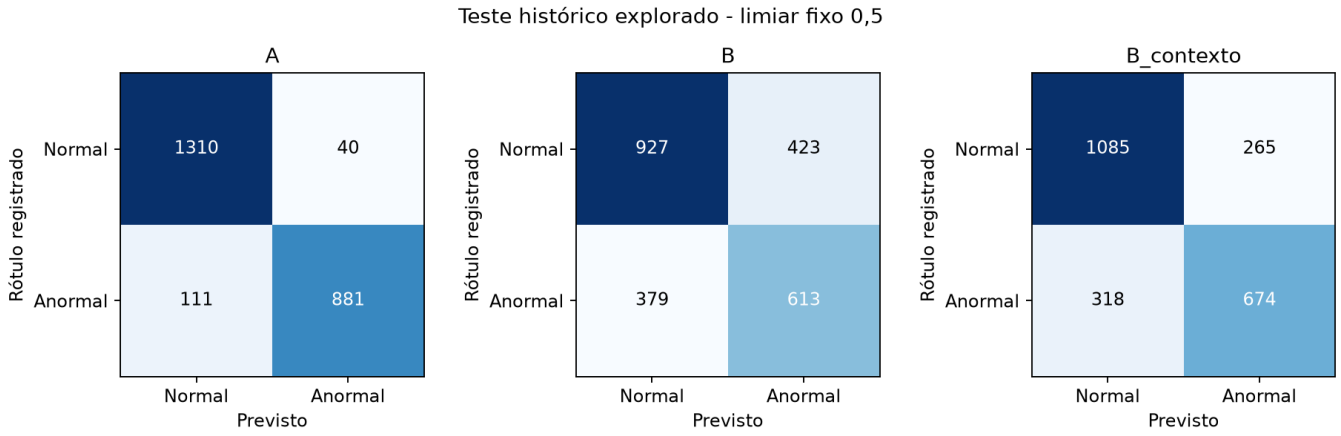
7.2 Tipos de erro, incerteza e controles

Usamos limiar fixo p>=0,5. Recall = TP/(TP+FN), precisão = TP/(TP+FP), especificidade = TN/(TN+FP) e BA = (recall+especificidade)/2. F1 combina precisão/recall. ROC-AUC avalia ordenação de scores e AP resume precisão-recall pela sua definição; AP não é área trapezoidal. Brier descreve erro quadrático do score probabilístico, sem provar calibração clínica.

O controle majoritário tem BA=0,500. A regra fixa de SOPRO cobre 99,8% do teste e tem BA=0,920 nessa cobertura. Os modelos também foram calculados no mesmo subconjunto para comparação justa. O score binário dessa regra não é probabilidade calibrada.

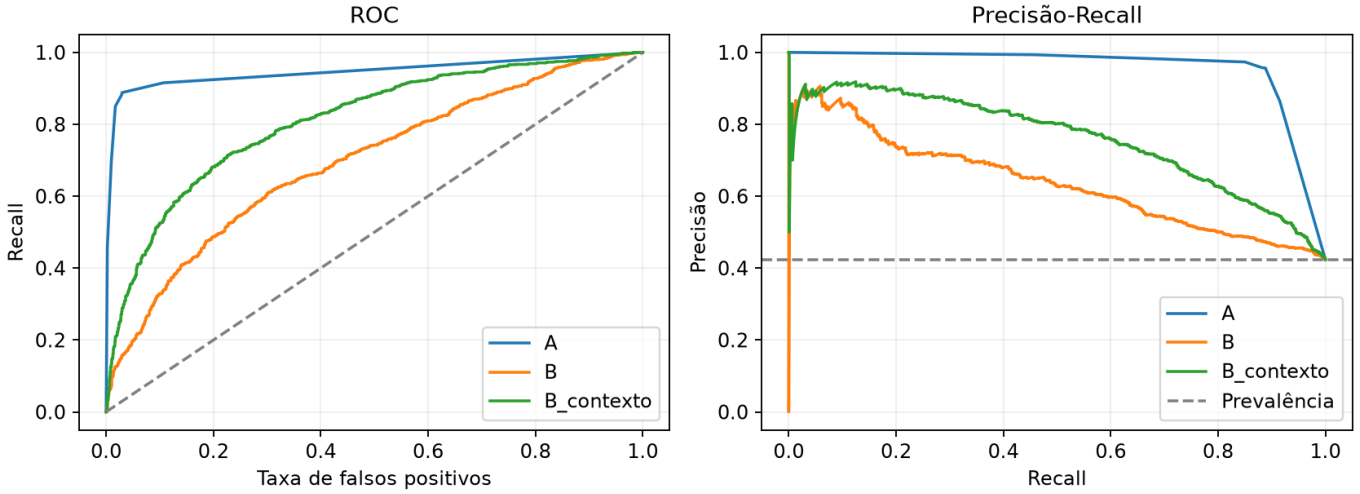
Os intervalos percentis usam 500 reamostragens dos componentes candidatos, condicionadas ao modelo já ajustado. Não abrangem toda a incerteza da preparação e seleção. Subgrupos publicam suporte e erros; Wilson de recall é descritivo por linha e não corrige dependência de grupo. A instabilidade de um subgrupo pequeno não deve virar uma conclusão geral.

Cenário	TN	FP	FN	TP	Especificidade	F1	IC95 BA
A	1310	40	111	881	0,970	0,921	0,918 a 0,939
B	927	423	379	613	0,687	0,605	0,632 a 0,674
B_contexto	1085	265	318	674	0,804	0,698	0,722 a 0,760



7.3 Curvas e limites de generalização

O limiar controla o compromisso entre erros. As curvas mostram possibilidades, mas nenhum ponto foi escolhido pelo teste. Formação do rótulo, identidade das pessoas, temporalidade dos achados e mudança de população ainda não estão confirmadas. Não executamos validação temporal com séculos ambíguos: uma janela histórica presumida não cria cronologia confiável.



8. Contestação das escolhas e testes de sensibilidade

Além da busca principal, contestamos o papel dos outliers, indicadores, atributos redundantes/esparsos e balanceamento. Sobreamostragem repete exemplos minoritários; subamostragem reduz majoritários; ambas ficam somente no treino e substituem o peso de classe, sem alterar validação ou teste. PCA95 é testada na melhor logística, com projeção aprendida em cada treino; deve ser comparada à mesma logística sem PCA, não atribuída à vencedora de outra família.

Em B, retirar IMC elevou BA média de 0,6341 para 0,6366: ganho de 0,0025, pequeno frente ao DP de 0,0092 dos folds da configuração principal. Isso é pista, não melhora confirmada. PCA reduziu BA em relação à mesma logística em todos os cenários: A: 0,9192 para 0,9174; B: 0,6186 para 0,6155; B_contexto: 0,7087 para 0,7071. Em A, várias intervenções não alteraram as decisões de classe: os achados de exame dominam esse resultado.

A tabela é exploratória e usa o desenvolvimento após a seleção principal. Um ganho pontual pede nova confirmação; não autoriza trocar o vencedor depois de observar o teste. Piorar também é resultado: informação rara, estimativa e redundância podem afetar cada cenário de modo diferente. Não forçamos toda técnica para acumular conceitos.

Variante	A: CV BA	B: CV BA	B_contexto: CV BA
PCA95 (logística)	0,917	0,616	0,707
Principal	0,919	0,634	0,713
Sem HDA2	0,919	-	0,712
Sem IMC	0,919	0,637	0,710
Sem IMC e HDA2	0,919	0,637	0,710
Sem PPA	0,919	-	0,711
Sem indicadores	0,919	0,627	0,711
Sobreamostragem	0,919	0,633	0,713
Subamostragem	0,919	0,629	0,711
Suspeitos preservados	0,919	0,635	0,711

9. Interpretação - cenário A

Na importância por permutação exploratória, os maiores efeitos foram SOPRO: queda 0,393; B2: queda 0,031; Peso: queda 0,000. O cálculo usa um fold de validação do desenvolvimento, não o treino desse modelo. A escolha de configuração já usou desenvolvimento, portanto a análise é pós-seleção. Permutar uma coluna pode quebrar correlações: queda de desempenho não é efeito causal de uma variável.

Para interpretar padrões legíveis, ajustamos também a melhor árvore por CV. As regras abaixo pertencem a essa árvore, que pode ser distinta do modelo vencedor. Suportes e frações são contagens reais no desenvolvimento, não probabilidades de nós ponderados por classe e não estimativas externas. As condições usam a representação após imputação. Um indicador nominal igual0 pode incluir campo vazio ou categoria inédita; não significa ausência clínica do achado.

Regra da árvore	n desenvolvimento	Anormais observados
SOPRO registrado como Ausente; B2 registrado como Normal; FC <= 115.5	5.136	7,7%
SOPRO diferente de Ausente (inclui falta/inédito); HDA 1 com registro; PA DIASTOLICA foi imputado	1.765	98,3%
SOPRO diferente de Ausente (inclui falta/inédito); HDA 1 com registro; PA DIASTOLICA não foi imputado	1.016	96,1%

9. Interpretação - cenário B

Na importância por permutação exploratória, os maiores efeitos foram FC: queda 0,048; Peso: queda 0,024; IDADE: queda 0,013. O cálculo usa um fold de validação do desenvolvimento, não o treino desse modelo. A escolha de configuração já usou desenvolvimento, portanto a análise é pós-seleção. Permutar uma coluna pode quebrar correlações: queda de desempenho não é efeito causal de uma variável.

Para interpretar padrões legíveis, ajustamos também a melhor árvore por CV. As regras abaixo pertencem a essa árvore, que pode ser distinta do modelo vencedor. Suportes e frações são contagens reais no desenvolvimento, não probabilidades de nós ponderados por classe e não estimativas externas. As condições usam a representação após imputação. Um indicador nominal igual0 pode incluir campo vazio ou categoria inédita; não significa ausência clínica do achado.

Regra da árvore	n desenvolvimento	Anormais observados
Peso > 8.85; FC <= 98.5; SEXO com registro; Peso > 28.85	1.968	28,2%
Peso > 8.85; FC <= 98.5; SEXO com registro; Peso <= 28.85; FC <= 89.5	1.804	33,1%
Peso > 8.85; FC > 98.5	1.671	49,3%

9. Interpretação - cenário B_contexto

Na importância por permutação exploratória, os maiores efeitos foram MOTIVO2: queda 0,053; MOTIVO1: queda 0,043; HDA 1: queda 0,013. O cálculo usa um fold de validação do desenvolvimento, não o treino desse modelo. A escolha de configuração já usou desenvolvimento, portanto a análise é pós-seleção. Permutar uma coluna pode quebrar correlações: queda de desempenho não é efeito causal de uma variável.

Para interpretar padrões legíveis, ajustamos também a melhor árvore por CV. As regras abaixo pertencem a essa árvore, que pode ser distinta do modelo vencedor. Suportes e frações são contagens reais no desenvolvimento, não probabilidades de nós ponderados por classe e não estimativas externas. As condições usam a representação após imputação. Um indicador nominal igual0 pode incluir campo vazio ou categoria inédita; não significa ausência clínica do achado.

Regra da árvore	n desenvolvimento	Anormais observados
MOTIVO2 diferente de 6 - sopro (inclui falta/inédito); MOTIVO2 diferente de 1 - cardiopatia congenica (inclui falta/inédito); FC <= 98.5; SEXO com registro; MOTIVO2 diferente de 5 - cirurgia (inclui falta/inédito); Peso > 21.15	1.540	23,1%
MOTIVO2 diferente de 6 - sopro (inclui falta/inédito); MOTIVO2 diferente de 1 - cardiopatia congenica (inclui falta/inédito); FC <= 98.5; SEXO com registro; MOTIVO2 diferente de 5 - cirurgia (inclui falta/inédito); Peso <= 21.15	1.377	33,6%
MOTIVO2 diferente de 6 - sopro (inclui falta/inédito); MOTIVO2 diferente de 1 - cardiopatia congenica (inclui falta/inédito); FC > 98.5; MOTIVO2 diferente de 5 - cirurgia (inclui falta/inédito); MOTIVO1 diferente de 2 - check-up (inclui falta/inédito); SEXO com registro	1.108	46,6%

10. Conhecimento obtido e aplicação responsável

A leitura integrada deve confrontar o desempenho com a informação disponível. A diferença entre A e B quantifica o valor preditivo de achados/contexto para o rótulo registrado, sem provar circularidade nem independência diagnóstica. Se um modelo rico apenas reproduz um exame que ajudou a formar o alvo, sua pontuação não demonstra capacidade de antecipar o diagnóstico. As medidas sozinhas precisam ser julgadas por seus próprios erros e incertezas.

A primeira aplicação, exigindo apenas um campo disponível, revelou um problema: A atribuía score a 430 registros sem alvo, embora muitos padrões de ausência tivessem suporte inexistente ou muito baixo no desenvolvimento. Rejeitamos essa regra como suficiente. A aplicação revisada exige algum preditor, categorias observadas e um padrão de disponibilidade visto em pelo menos 30 exemplos do treino. Comparamos coberturas para suportes 1/10/30 sem usar rótulos novos nem retunar os modelos. O corte de 30 é operacional, não ótimo comprovado.

A aplicação revisada mantém score para 19 registros em A, 380 em B e 294 em B_contexto; os demais recebem status de abstenção. A pode discriminar melhor registros completos e ao mesmo tempo cobrir muito menos registros sem alvo. Essa é uma descoberta sobre os limites de uso, não um motivo para forçar resultados. Cobertura aceita não prova confiabilidade individual. Predições não viram y ou pseudo-rótulos.

Cenário	Sem alvo	Com score	Abstenções	Score>=0,5
A	1169	19	1150	6
B	1169	380	789	158
B_contexto	1169	294	875	81

10.1 Cobertura em dados rotulados e limites da política

A política de suporte foi definida sem selecionar por acurácia do teste. Como diagnóstico secundário, publicamos sua cobertura no teste histórico e o desempenho condicionado aos casos aceitos. Esses números não substituem o teste completo e não podem ser comparados sem considerar a mudança de denominador. A diferença entre a cobertura no teste rotulado e nos não rotulados evidencia uma mudança no padrão de informação disponível.

Cenário	Aceitos / teste	Cobertura %	BA nos aceitos
A	2008 / 2342	85,7	0,931
B	2272 / 2342	97,0	0,648
B_contexto	2011 / 2342	85,9	0,746

11. Síntese crítica e uso do conhecimento

O processo completo foi executado, mas sua validade é acadêmica e condicionada às hipóteses registradas. O uso sustentado é documentar os padrões e melhorar a coleta: confirmar unidade paciente/atendimento e formação do alvo, preservar datas completas/unidades e registrar quando cada achado foi obtido. Uma implantação clínica ou eficácia diagnóstica não decorre desses experimentos.

O registro estruturado contém 217 decisões e configurações, além de todos os parâmetros aprendidos por fold e finais. O conjunto de alternativas foi amplo e explícito; não se afirma ótimo universal. O cuidado decisivo foi impedir que a busca escolhesse pela pontuação do teste e expor os resultados que contradizem preferências iniciais.

12. Reprodução, conceitos e fontes

Conceitos empregados: KDD iterativo, tipos/escalas, análise univariada/bivariada, ausências e inconsistências, outliers, criação/redução de atributos, mediana, discretização, one-hot, log, padronização, balanceamento, generalização, complexidade/sobreajuste, hold-out, estratificação, grupos, CV, nested CV, tuning, pipeline, matriz de confusão, precisão/recall/F1/BA e curvas ROC/PR. Regressão logística, floresta, AP/Brier, Welch, V de Cramér e intervalos por grupos são complementos explicitados, sem presumir que sua explicação integral esteja nos materiais.

Os dados clínicos e saídas por registro permanecem locais; o repositório contém código, decisões, parâmetros agregados, métricas e notebook. O comando run_full_kdd.py reproduz preparação, mineração e relatório. O notebook completo executa ou confere essa mesma biblioteca, valida os artefatos e reaplica modelos salvos. Versões, SHA da fonte, partições, configurações e seeds são registrados.

Fontes: materiais locais de fundamentos, dados, exploração, limpeza, transformação e avaliação experimental da disciplina; dicionário e tema UCMF; orientação do professor comunicada pelo grupo. APIs verificadas na documentação oficial scikit-learn: prevenção de vazamento, validação cruzada, árvores e avaliação de modelos. Uso de IA: Codex auxiliou investigação, implementação, comparações, testes e redação. A compreensão e defesa oral do trabalho exigem leitura dos integrantes.