A2 - Revisão do pré-processamento

Mineração de Dados - UFG | Pedro Matos, João Vitor Fernandes, Mateus Nery e Antônio Henrique | 04/11/2026

Escopo: dados e representações aplicadas antes da modelagem. Revisão integrante da A2; a A1 já entregue permanece como registro da avaliação. A modelagem atual está no relatório integrado do KDD.

1. População e decisões de base

A entrada contém **12.873 registros e 21 variáveis**. Todas as linhas e IDs são preservados. Há **11.704 alvos conhecidos**; desconhecidos não são imputados. Igualdade de atributos não prova duplicação de paciente. ID, datas e convênio ficam fora da matriz principal.

2. Univariada numérica antes de imputar

População completa; política de mascaramento declarada. Ausência inclui valores invalidados ou mascarados. Quartis, média e dispersão usam somente medidas disponíveis; estimativas da matriz não entram nesta descrição.

Campo	n	Aus.	Média	Med.	DP	Q1 a Q3	Mín. a máx.
Peso	9.929	22,9%	21,0	16,0	16,4	9,1 a 28,0	1,0 a 127,0
Altura	8.395	34,8%	101,2	100,0	35,4	71,0 a 129,0	36,0 a 198,0
IMC	8.023	37,7%	17,4	16,7	3,8	15,1 a 18,9	5,9 a 87,8
Idade	11.226	12,8%	5,0	3,9	4,5	1,0 a 8,3	0,0 a 19,9
PAS	5.140	60,1%	101,5	100,0	11,6	90,0 a 110,0	60,0 a 180,0
PAD	5.132	60,1%	62,6	60,0	9,1	60,0 a 70,0	6,0 a 120,0
FC	10.995	14,6%	95,2	92,0	18,2	80,0 a 100,0	8,0 a 300,0

Idade: uma correção fundamentada

Em 11.191 casos comparáveis, a idade recebida acompanha dias/352 a até 0,01 ano; 11.120 coincidem exatamente após arredondamento. Isso não estabelece a fórmula da planilha, mas impede tratar a coluna recebida como cronologicamente correta. Recalculamos idade relativa quando os pares de datas são compatíveis e suficientemente precisos.

Não fixamos século absoluto por conveniência. O intervalo de idade e a hipótese do recorte 0-19 anos completos ficam registrados. O aniversário de 20 anos não pertence ao recorte. Idade original e valores negativos continuam na auditoria; fallback é identificado como menos confiável.

ID e datas são descritos por cobertura, formatos, candidatos e estados, não por média numérica de códigos. Datas inexistentes ou com texto residual não são reconstruídas por palpite.

2. Univariada categórica (continuação)

Denominador: 12.873 registros. São exibidas até duas categorias frequentes; o complemento mantém todas as categorias, contagens e faltantes. Ausente em SOPRO é achado observado, não falta de registro.

Campo	Cat.	Aus.	Categorias frequentes
Convenio	257	31,9%	GS: 2.099 (16,3%); UR: 1.482 (11,5%)
PULSOS	5	9,3%	Normais: 11.533 (89,6%); Amplos: 53 (0,4%)
PPA	7	83,8%	normal: 1.790 (13,9%); has-2 pas: 73 (0,6%)
NORMAL X ANORMAL	2	9,1%	Normal: 6.744 (52,4%); Anormal: 4.960 (38,5%)
B2	5	9,2%	Normal: 11.098 (86,2%); Hiperfonetica: 295 (2,3%)
SOPRO	5	9,1%	Ausente: 7.275 (56,5%); Sistolico: 4.371 (34,0%)
HDA 1	8	33,2%	assintomatico: 6.561 (51,0%); dispneia: 541 (4,2%)
HDA2	8	96,8%	dispneia: 83 (0,6%); palpitacao: 83 (0,6%)
SEXO	2	11,0%	M: 6.728 (52,3%); F: 4.724 (36,7%)
MOTIVO1	5	8,2%	5 - parecer cardiologico: 5.352 (41,6%); 6 - suspeita de cardiopatia: 4.285 (33,3%)
MOTIVO2	16	27,2%	5 - cirurgia: 2.940 (22,8%); 6 - sopro: 2.349 (18,2%)

Retenção e redução

PULSOS, B2 e SOPRO conservam categorias raras. HDA2 continua disponível na representação completa; uma alternativa reduzida permite retirá-la junto ao IMC. A regra de 50% de vazios ou de valores repetidos é uma heurística, não uma remoção clínica automática.

Convênio permanece na base semântica e na análise, mas não na matriz principal: alta cardinalidade administrativa e finalidade distinta. Prefixos numéricos de MOTIVO2 não identificam categorias únicas; preserva-se a descrição completa.

Os contextos e achados não são declarados seguros para triagem antes do diagnóstico. Esta preparação conserva e transforma a informação; a escolha da disponibilidade em cada cenário deverá ser reavaliada antes da modelagem.

3. Limpeza: decisão, motivo e alternativa

Campos	O que foi decidido	Por que / cuidado
ID / repetições	Preservar rastreio e sinalizar equivalências.	Não provar identidade nem excluir coincidências por vacuidade.
Peso / Altura	Zero-sentinela vira ausente; formato inválido é rejeitado; extremos são flags.	Não apagar idade porque o corpo destoa; separar suspeita de erro.
IMC	Recalcular só com pais observados utilizáveis; guardar histórico/origem.	Não produzir uma medição clínica com pais imputados.
Atendimento / DN	Parser completo, candidatos de século e estado de cada data.	Não escolher data absoluta para forçar idade pediátrica.
IDADE	Idade relativa com intervalo e regra do recorte; original bruto preservado.	Não confiar na coluna compatível com dias/352; não imputar idade pelo corpo circularmente.
PAS / PAD	Flag relacional PAS≤PAD; nessa variante mascarar ambas, preservando originais.	Não decidir qual componente errou; não converter imputação em HAS.
PPA / alvo	Sentinelas de PPA viram ausência; alvo só por rótulos documentados.	PPA é histórica; alvo não é imputado e Normais continua em revisão.
PULSOS / B2 / SOPRO	Grafias equivalentes normalizadas; raros mantidos.	Não usar moda Normal/Ausente como exame inventado.
FC	Faixa válida vira ponto médio com flag; invertida é invalidada.	Aproximação não é leitura exata nem diagnóstico.
SEXO	Grafias M/F documentadas; desconhecido explícito.	Não inferir sexo pelo corpo, alvo ou moda.
HDA1 / HDA2 / MOTIVOS	Categorias completas e falta explícita; sem copiar entre campos.	Não declarar vazio como ausência de sintomas ou de outro motivo.
Convênio	Normalizar sem adivinhar operadora; retirar da matriz principal.	Não selecionar pelo alvo nem confundir rotina institucional com sinal clínico.

Os envelopes antigos são alertas, não prova de erro. A revisão preserva extremos potencialmente reais. A verificação conjunta sinaliza IMC fora do intervalo operacional amplo 5-100: mascara o trio na matriz, preservando original e idade, sem decidir o culpado. Isso não é faixa clínica de normalidade nem prova de erro individual.

4. Transformações realmente aplicadas

Ajuste somente no desenvolvimento da partição congelada; aplicação sem reajuste ao teste, às demais linhas e aos não rotulados. Não houve treinamento de classificador nesta rodada. ID e y são separados de X.

Conceitos usados: tipos/escalas, ausência, tendência central, codificação categórica, criação de atributos, redução, transformação logarítmica e padronização.

Imputação julgada por reconstrução no desenvolvimento

Campo	Global: MAE	Por idade	Idade + sexo
Peso	12,00	5,42	5,37
Altura	29,58	9,13	9,05
FC	13,26	9,62	9,61
IMC	2,53	2,27	2,27
PAS	7,80	7,61	7,63
PAD	5,76	5,64	5,64

Cinco repetições: 20% de valores disponíveis ocultados; medianas ajustadas sem essas células. Faixas fixas exigem 30 observados, com fallback. A mediana por idade é uma aplicação da imputação por tendência central; o diagnóstico não prova o mecanismo real das ausências e não usa o alvo.

Escolha aplicada: por faixa etária em Peso, Altura, IMC, FC; global em Idade, PAS, PAD. Sexo não acrescentou ganho suficiente para fragmentar os grupos. A escolha do IMC é limítrofe no mascaramento; a variante global também está disponível.

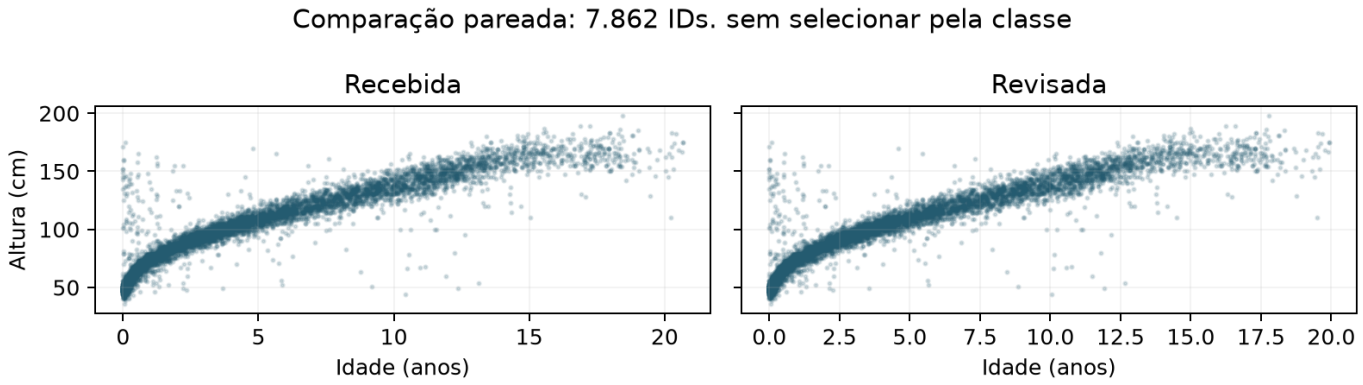
Representação	Transformações aplicadas
Unidades originais	Imputação escolhida por coluna; one-hot dos nominais; indicadores de estimativa/falta/inédito.
Z-score	Somente medidas contínuas são centradas e reescaladas; categorias e indicadores ficam 0/1.
Log-Peso + Z-score	Alternativa: log1p somente em Peso e depois escala contínua; não se aplica log aos indicadores.

A idade usada para escolher o grupo é a disponível antes de imputar; não se cria grupo com idade estimada. IMC não é recalculado depois de preencher os pais. Categorias inéditas têm tratamento explícito, sem ampliar o vocabulário pelo teste. Não há garantia de transformação universalmente ótima antes de definir algoritmo/finalidade.

Matriz completa: **12.873 × 93**, finita, com ID/y separados. Parâmetros ajustados em **9.361** registros; teste 2.342. A quarentena retira do ajuste o candidato que cruza a partição, sem excluir a linha da base. CV futura exige novo ajuste em cada fold.

5. Comparação pareada e relação com o alvo

Altura × idade: mesmos 7.862 IDs, disponíveis nas duas versões. Pearson 0,927 → 0,927; Spearman 0,959 → 0,959. A relação descreve associação; não valida a limpeza por si.



Bivariadas numéricas: somente rótulos conhecidos

Campo	n N/A	Med. N/A	Δ média A-N	IC95% Δ
Peso	5.441/4.129	19,0/13,0	-6,99	-7,63 a -6,35
Altura	4.580/3.480	107,0/90,0	-16,90	-18,41 a -15,38
IMC	4.382/3.312	17,1/16,2	-1,13	-1,29 a -0,96
Idade	6.210/4.628	4,8/2,6	-1,78	-1,94 a -1,61
PAS	3.276/1.851	100,0/100,0	-0,18	-0,88 a 0,51
PAD	3.273/1.846	60,0/60,0	-0,56	-1,09 a -0,03
FC	6.374/4.601	90,0/98,0	8,13	7,43 a 8,82

O intervalo de Welch compara médias, não medianas, e é complemento exploratório. A análise categórica completa publica contingências, V de Cramér e esperadas; p assintótico é omitido quando as esperadas não sustentam o teste. Associação não prova causa; falta de significância não prova equivalência.

SOPRO apresenta associação descritiva forte (V de Cramér 0,842); MOTIVO2 0,438 e B2 0,246. Esses achados podem participar do processo de rotulagem. Não se conclui causalidade ou capacidade de triagem anterior ao exame; categorias raras exigem atenção às esperadas.

Fontes e limites

Tema, dicionário e descrição das avaliações do SIGAA; conceitos das aulas de dados, limpeza, transformação e avaliação. Documentação oficial scikit-learn: pré-processamento e prevenção de vazamento. Percentis clínicos não verificados não foram inventados. O significado do alvo e a unidade paciente/consulta ainda precisam de esclarecimento.

IA: Codex auxiliou auditoria, código, comparações, testes e redação. Os materiais exigem leitura dos integrantes antes de entrega. As verificações técnicas não representam validação clínica. Complementos completos: decisões das 21 variáveis, tabelas, parâmetros e testes no repositório Data-Mining.