## A2 - Revisão do pré-processamento

Mineração de Dados - UFG | Pedro Matos, João Vitor Fernandes, Mateus Nery e Antônio Henrique | 04/11/2026

**Escopo:** dados e representações aplicadas antes da modelagem. Revisão integrante da A2; a A1 já entregue permanece como registro da avaliação. Os experimentos anteriores ainda não foram recalculados.

### 1. População e decisões de base

A entrada contém **12.873 registros e 21 variáveis**. Todas as linhas e IDs são preservados. Há **11.704 alvos conhecidos**; desconhecidos não são imputados. Igualdade de atributos não prova duplicação de paciente. ID, datas e convênio ficam fora da matriz principal.

### 2. Univariada numérica antes de imputar

População completa; política de mascaramento declarada. Ausência inclui valores invalidados ou mascarados. Quartis, média e dispersão usam somente medidas disponíveis; estimativas da matriz não entram nesta descrição.

| Campo | n | Aus. | Média | Med. | DP | Q1 a Q3 | Mín. a máx. |
|---|---|---|---|---|---|---|---|
| Peso | 9.929 | 22,9% | 21,0 | 16,0 | 16,4 | 9,1 a 28,0 | 1,0 a 127,0 |
| Altura | 8.395 | 34,8% | 101,2 | 100,0 | 35,4 | 71,0 a 129,0 | 36,0 a 198,0 |
| IMC | 8.023 | 37,7% | 17,4 | 16,7 | 3,8 | 15,1 a 18,9 | 5,9 a 87,8 |
| Idade | 11.226 | 12,8% | 5,0 | 3,9 | 4,5 | 1,0 a 8,3 | 0,0 a 19,9 |
| PAS | 5.140 | 60,1% | 101,5 | 100,0 | 11,6 | 90,0 a 110,0 | 60,0 a 180,0 |
| PAD | 5.132 | 60,1% | 62,6 | 60,0 | 9,1 | 60,0 a 70,0 | 6,0 a 120,0 |
| FC | 10.995 | 14,6% | 95,2 | 92,0 | 18,2 | 80,0 a 100,0 | 8,0 a 300,0 |

### Idade: uma correção fundamentada

Em 11.191 casos comparáveis, a idade recebida acompanha dias/352 a até 0,01 ano; 11.120 coincidem exatamente após arredondamento. Isso não estabelece a fórmula da planilha, mas impede tratar a coluna recebida como cronologicamente correta. Recalculamos idade relativa quando os pares de datas são compatíveis e suficientemente precisos.

Não fixamos século absoluto por conveniência. O intervalo de idade e a hipótese do recorte 0-19 anos completos ficam registrados. O aniversário de 20 anos não pertence ao recorte. Idade original e valores negativos continuam na auditoria; fallback é identificado como menos confiável.

ID e datas são descritos por cobertura, formatos, candidatos e estados, não por média numérica de códigos. Datas inexistentes ou com texto residual não são reconstruídas por palpite.

## 2. Univariada categórica (continuação)

Denominador: 12.873 registros. São exibidas até duas categorias frequentes; o complemento mantém todas as categorias, contagens e faltantes. Ausente em SOPRO é achado observado, não falta de registro.

| Campo | Cat. | Aus. | Categorias frequentes |
|---|---|---|---|
| Convenio | 257 | 31,9% | GS: 2.099 (16,3%); UR: 1.482 (11,5%) |
| PULSOS | 5 | 9,3% | Normais: 11.533 (89,6%); Amplos: 53 (0,4%) |
| PPA | 7 | 83,8% | normal: 1.790 (13,9%); has-2 pas: 73 (0,6%) |
| NORMAL X ANORMAL | 2 | 9,1% | Normal: 6.744 (52,4%); Anormal: 4.960 (38,5%) |
| B2 | 5 | 9,2% | Normal: 11.098 (86,2%); Hiperfonetica: 295 (2,3%) |
| SOPRO | 5 | 9,1% | Ausente: 7.275 (56,5%); Sistolico: 4.371 (34,0%) |
| HDA 1 | 8 | 33,2% | assintomatico: 6.561 (51,0%); dispneia: 541 (4,2%) |
| HDA2 | 8 | 96,8% | dispneia: 83 (0,6%); palpitacao: 83 (0,6%) |
| SEXO | 2 | 11,0% | M: 6.728 (52,3%); F: 4.724 (36,7%) |
| MOTIVO1 | 5 | 8,2% | 5 - parecer cardiologico: 5.352 (41,6%); 6 - suspeita de cardiopatia: 4.285 (33,3%) |
| MOTIVO2 | 16 | 27,2% | 5 - cirurgia: 2.940 (22,8%); 6 - sopro: 2.349 (18,2%) |

### Retenção e redução

PULSOS, B2 e SOPRO conservam categorias raras. HDA2 continua disponível na representação completa; uma alternativa reduzida permite retirá-la junto ao IMC. A regra de 50% de vazios ou de valores repetidos é uma heurística, não uma remoção clínica automática.

Convênio permanece na base semântica e na análise, mas não na matriz principal: alta cardinalidade administrativa e finalidade distinta. Prefixos numéricos de MOTIVO2 não identificam categorias únicas; preserva-se a descrição completa.

Os contextos e achados não são declarados seguros para triagem antes do diagnóstico. Esta preparação conserva e transforma a informação; a escolha da disponibilidade em cada cenário deverá ser reavaliada antes da modelagem.

### 3. Limpeza: decisão, motivo e alternativa

| Campos | O que foi decidido | Por que / cuidado |
|---|---|---|
| ID / repetições | Preservar rastreio e sinalizar equivalências. | Não provar identidade nem excluir coincidências por vacuidade. |
| Peso / Altura | Zero-sentinela vira ausente; formato inválido é rejeitado; extremos são flags. | Não apagar idade porque o corpo destoa; separar suspeita de erro. |
| IMC | Recalcular só com pais observados utilizáveis; guardar histórico/origem. | Não produzir uma medição clínica com pais imputados. |
| Atendimento / DN | Parser completo, candidatos de século e estado de cada data. | Não escolher data absoluta para forçar idade pediátrica. |
| IDADE | Idade relativa com intervalo e regra do recorte; original bruto preservado. | Não confiar na coluna compatível com dias/352; não imputar idade pelo corpo circularmente. |
| PAS / PAD | Flag relacional PAS≤PAD; nessa variante mascarar ambas, preservando originais. | Não decidir qual componente errou; não converter imputação em HAS. |
| PPA / alvo | Sentinelas de PPA viram ausência; alvo só por rótulos documentados. | PPA é histórica; alvo não é imputado e Normais continua em revisão. |
| PULSOS / B2 / SOPRO | Grafias equivalentes normalizadas; raros mantidos. | Não usar moda Normal/Ausente como exame inventado. |
| FC | Faixa válida vira ponto médio com flag; invertida é invalidada. | Aproximação não é leitura exata nem diagnóstico. |
| SEXO | Grafias M/F documentadas; desconhecido explícito. | Não inferir sexo pelo corpo, alvo ou moda. |
| HDA1 / HDA2 / MOTIVOS | Categorias completas e falta explícita; sem copiar entre campos. | Não declarar vazio como ausência de sintomas ou de outro motivo. |
| Convênio | Normalizar sem adivinhar operadora; retirar da matriz principal. | Não selecionar pelo alvo nem confundir rotina institucional com sinal clínico. |

Os envelopes antigos são alertas, não prova de erro. A revisão preserva extremos potencialmente reais. A verificação conjunta sinaliza IMC fora do intervalo operacional amplo 5-100: mascara o trio na matriz, preservando original e idade, sem decidir o culpado. Isso não é faixa clínica de normalidade nem prova de erro individual.

## 4. Transformações realmente aplicadas

Ajuste somente no desenvolvimento da partição congelada; aplicação sem reajuste ao teste, às demais linhas e aos não rotulados. Não houve treinamento de classificador nesta rodada. ID e y são separados de X.

**Conceitos usados:** tipos/escalas, ausência, tendência central, codificação categórica, criação de atributos, redução, transformação logarítmica e padronização.

### Imputação julgada por reconstrução no desenvolvimento

| Campo | Global: MAE | Por idade | Idade + sexo |
|---|---|---|---|
| Peso | 12,00 | 5,42 | 5,37 |
| Altura | 29,58 | 9,13 | 9,05 |
| FC | 13,26 | 9,62 | 9,61 |
| IMC | 2,53 | 2,27 | 2,27 |
| PAS | 7,80 | 7,61 | 7,63 |
| PAD | 5,76 | 5,64 | 5,64 |

Cinco repetições: 20% de valores disponíveis ocultados; medianas ajustadas sem essas células. Faixas fixas exigem 30 observados, com fallback. A mediana por idade é uma aplicação da imputação por tendência central; o diagnóstico não prova o mecanismo real das ausências e não usa o alvo.

**Escolha aplicada:** por faixa etária em Peso, Altura, IMC, FC; global em Idade, PAS, PAD. Sexo não acrescentou ganho suficiente para fragmentar os grupos. A escolha do IMC é limítrofe no mascaramento; a variante global também está disponível.

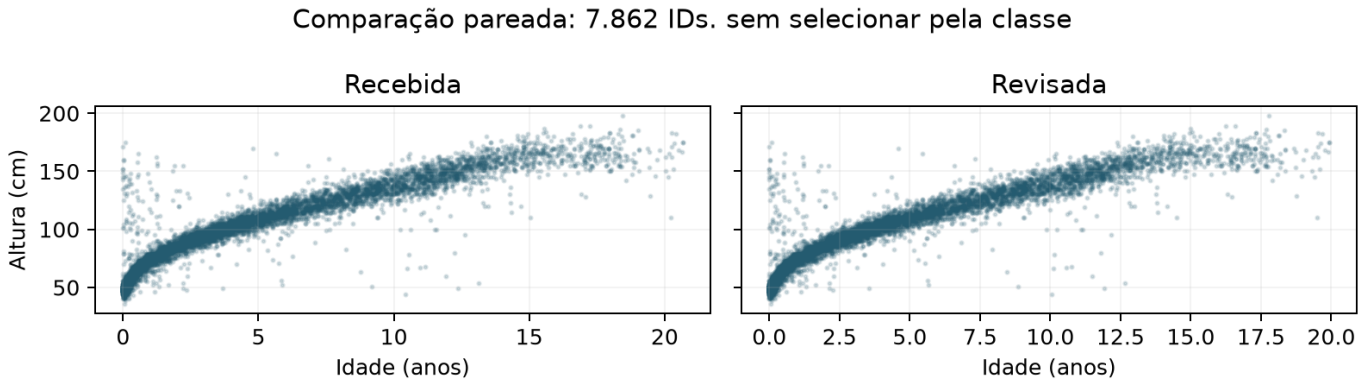
| Representação | Transformações aplicadas |
|---|---|
| Unidades originais | Imputação escolhida por coluna; one-hot dos nominais; indicadores de estimativa/falta/inédito. |
| Z-score | Somente medidas contínuas são centradas e reescaladas; categorias e indicadores ficam 0/1. |
| Log-Peso + Z-score | Alternativa: log1p somente em Peso e depois escala contínua; não se aplica log aos indicadores. |

A idade usada para escolher o grupo é a disponível antes de imputar; não se cria grupo com idade estimada. IMC não é recalculado depois de preencher os pais. Categorias inéditas têm tratamento explícito, sem ampliar o vocabulário pelo teste. Não há garantia de transformação universalmente ótima antes de definir algoritmo/finalidade.

Matriz completa: **12.873 × 93**, finita, com ID/y separados. Parâmetros ajustados em **9.361** registros; teste 2.342. A quarentena retira do ajuste o candidato que cruza a partição, sem excluir a linha da base. CV futura exige novo ajuste em cada fold.

### 5. Comparação pareada e relação com o alvo

Altura × idade: mesmos 7.862 IDs, disponíveis nas duas versões. Pearson 0,927 → 0,927; Spearman 0,959 → 0,959. A relação descreve associação; não valida a limpeza por si.




### Bivariadas numéricas: somente rótulos conhecidos

| Campo | n N/A | Med. N/A | Δ média A-N | IC95% Δ |
|---|---|---|---|---|
| Peso | 5.441/4.129 | 19,0/13,0 | -6,99 | -7,63 a -6,35 |
| Altura | 4.580/3.480 | 107,0/90,0 | -16,90 | -18,41 a -15,38 |
| IMC | 4.382/3.312 | 17,1/16,2 | -1,13 | -1,29 a -0,96 |
| Idade | 6.210/4.628 | 4,8/2,6 | -1,78 | -1,94 a -1,61 |
| PAS | 3.276/1.851 | 100,0/100,0 | -0,18 | -0,88 a 0,51 |
| PAD | 3.273/1.846 | 60,0/60,0 | -0,56 | -1,09 a -0,03 |
| FC | 6.374/4.601 | 90,0/98,0 | 8,13 | 7,43 a 8,82 |

O intervalo de Welch compara médias, não medianas, e é complemento exploratório. A análise categórica completa publica contingências, V de Cramér e esperadas; p assintótico é omitido quando as esperadas não sustentam o teste. Associação não prova causa; falta de significância não prova equivalência.

SOPRO apresenta associação descritiva forte (V de Cramér 0,842); MOTIVO2 0,438 e B2 0,246. Esses achados podem participar do processo de rotulagem. Não se conclui causalidade ou capacidade de triagem anterior ao exame; categorias raras exigem atenção às esperadas.

### Fontes e limites

Tema, dicionário e descrição das avaliações do SIGAA; conceitos das aulas de dados, limpeza, transformação e avaliação. Documentação oficial scikit-learn: pré-processamento e prevenção de vazamento. Percentis clínicos não verificados não foram inventados. O significado do alvo e a unidade paciente/consulta ainda precisam de esclarecimento.

IA: Codex auxiliou auditoria, código, comparações, testes e redação. Os materiais exigem leitura dos integrantes antes de entrega. As verificações técnicas não representam validação clínica. Complementos completos: decisões das 21 variáveis, tabelas, parâmetros e testes no repositório Data-Mining.