Classificação de registros clínicos com auditoria de vazamento de informação

Antônio Henrique Queiroz Villar Lopes, João Vitor Fernandes Ferreira
Mateus Nery Bailão, Pedro Augusto Ferreira Matos
Instituto de Informática, Universidade Federal de Goiás (UFG)
Mineração de Dados (2026/2), Goiânia, Brasil

***Resumo*—Investigamos a classificação binária do rótulo cardíaco registrado na base pediátrica UCMF, com atenção à possibilidade de vazamento de informação. Auditamos os 21 atributos e excluímos dos preditores motivos de encaminhamento com conteúdo diagnóstico, achados do exame cardiovascular e campos de proveniência incerta. Com 9.361 registros de desenvolvimento, comparamos uma referência majoritária, árvore de decisão, regressão logística e floresta aleatória em validação cruzada aninhada, estratificada e agrupada. Imputação, codificação e escalonamento foram ajustados em cada treino. A floresta alcançou acurácia balanceada de 62,87% e sensibilidade de 59,29% no cenário fisiológico. Com quatro atributos antropométricos e demográficos, a regressão logística obteve a maior acurácia balanceada, de 59,74%. A mudança na ordenação das famílias indica dependência do conjunto de entradas. A cronologia da coleta e a origem do rótulo limitam a interpretação clínica.**

***Index Terms*—classificação, dados clínicos, validação cruzada, vazamento de informação.**

I. Introdução

A base UCMF reúne registros de atendimento cardiológico pediátrico. O dicionário descreve a variável *NORMAL X ANORMAL* em termos de presença ou ausência de patologia cardíaca [1], [2]. Consideramos *Anormal* a classe positiva e investigamos em que medida características antropométricas, demográficas e fisiológicas discriminam esse rótulo. A fonte disponível deixa em aberto a ordem de registro dos campos, a identidade do responsável pela rotulagem e o padrão diagnóstico de referência. Essas lacunas afetam tanto a escolha dos preditores quanto o significado dos resultados.

Na avaliação anterior, o trabalho chegou à transformação dos dados. Nesta A2, revimos seleção, limpeza e transformação e completamos a mineração e a interpretação do processo KDD. O desenho compara famílias de modelos sob as mesmas partições e usa dois conjuntos de atributos para avaliar quanto a conclusão depende de medidas mais próximas da avaliação cardiovascular.

II. Dados e análise exploratória

Os dados foram coletados no Real Hospital Português, em Recife, e disponibilizados para o estudo de caso da disciplina [1]. A fonte contém 12.873 registros e 21 atributos. Há 1.169 registros sem rótulo, retirados da avaliação supervisionada. Dos 11.704 rotulados, 9.361 compõem o desenvolvimento, 2.342 pertencem ao teste histórico e um registro foi retirado do desenvolvimento por equivalência candidata com o teste. No desenvolvimento há 5.394 rótulos *Normal* e 3.967 *Anormal* (42,38%). Preservamos a partição histórica para evitar nova pontuação de um teste já examinado no projeto. Os 9.279 componentes candidatos reúnem equivalências de registro para restringir os cortes da validação cruzada. A identidade longitudinal dos pacientes permanece indeterminada.

Repositório público e código reprodutível: https://github.com/pedroafm06/Data-Mining-A2.

A. Auditoria da disponibilidade

Revisamos o significado, a origem documentada, a dependência de outros campos e a disponibilidade plausível de cada atributo. A Tabela I resume a decisão. A A1 já havia indicado o risco de MOTIVO1 e MOTIVO2. Na fonte, 1.158 registros trazem *Cardiopatia já estabelecida* em MOTIVO1 e 1.041 trazem *Cardiopatia congenica* em MOTIVO2. O conteúdo diagnóstico é observável. Seu momento de registro em relação ao alvo permanece desconhecido.

O material complementar cita SOPRO, B2 e PULSOS na investigação diagnóstica [3]. Isso sustenta a possibilidade de incorporação ao critério do rótulo. O procedimento efetivo de rotulagem da UCMF permanece sem documentação. PPA é uma classificação de hipertensão a partir de medidas e referências pediátricas [4]. Excluir PPA ainda deixa suas medidas de origem disponíveis. HDA1 e HDA2 contêm história e sintomas cuja disponibilidade anterior à classificação é incerta. Retiramos esses blocos por razões de proveniência e relação potencial com o alvo.

B. Associação e qualidade de dados

Ensaios com uma árvore fixa e uma variável por vez, em cinco partições agrupadas, serviram de diagnóstico exploratório. SOPRO atingiu acurácia balanceada de 91,05%, MOTIVO1 de 67,26%, MOTIVO2 de 68,69% e B2 de 55,32%. A decisão de exclusão seguiu a auditoria semântica e de proveniência. A pontuação isolada mede associação sob aquela configuração, que pode ser baixa mesmo quando há risco de vazamento. O desempenho de SOPRO é compatível com sua proximidade ao rótulo e admite explicações distintas, entre elas valor informativo clínico e incorporação ao critério.

A Fig. 1 mostra indisponibilidade após a limpeza e antes da imputação. A pressão arterial tem muito mais ausências do que FC. A mediana de FC é de 90 bpm em *Normal* e 98 bpm em *Anormal*. Os intervalos interquartis (80 a 100 e 88 a 110

Tabela I
DECISÃO SOBRE OS 21 ATRIBUTOS ORIGINAIS

Atributos	Decisão nos experimentos
NORMAL X ANORMAL	Resposta binária.
ID	Rastreabilidade e agrupamento candidato.
Atendimento, DN	Insumos para conferir ou derivar IDADE. Datas brutas fora de X.
Convênio	Excluído. Pode refletir acesso e encaminhamento.
MOTIVO1, MOTIVO2	Excluídos. Conteúdo diagnóstico explícito.
SOPRO, B2, PULSOS	Excluídos. Achados potencialmente incorporados ao rótulo.
PPA	Excluído. Classificação derivada de pressão.
HDA1, HDA2	Excluídos. Ordem de coleta e registro incerta.
Peso, Altura, IDADE, SEXO	Incluídos em FISIO8 e STRICT4.
IMC, PAS, PAD, FC	Incluídos em FISIO8 sob hipótese de disponibilidade. Retirados de STRICT4.

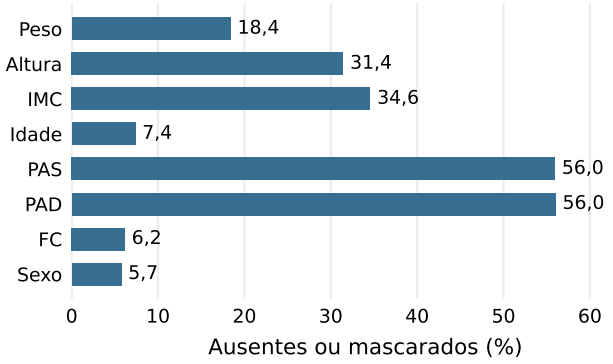


Figura 1. Percentual de ausências ou valores mascarados no desenvolvimento, após a limpeza e antes da imputação.

bpm) se sobrepõem. Isso fundamenta a análise de sensibilidade e o controle com apenas máscaras de disponibilidade, pois um modelo pode aprender também o padrão de coleta.

III. METODOLOGIA

A. Limpeza e transformação

A fonte foi preservada. Padronizamos grafias, separadores decimais e códigos de ausência, convertendo as medidas às unidades do dicionário. As regras por registro usam coerência entre campos e limites amplos de plausibilidade. Medidas suspeitas são mascaradas com registro da regra. Conservar a linha permite usar suas demais informações. A correção de altura em centímetros depende da coerência com a escala do campo. Para IMC, usamos a relação peso dividido pela altura em metros ao quadrado quando ambos os insumos são válidos, com preservação controlada do valor histórico quando essa reconstrução é inviável. Para IDADE, a diferença entre nascimento e atendimento é usada quando a interpretação das datas é coerente. O valor informado tem papel de referência nas ambiguidades de formato e século. As regras e exceções por variável foram documentadas na auditoria.

Em cada treino, comparamos a mediana global com medianas em faixas fixas de idade para Peso, Altura, IMC e FC quando presentes. A faixa requer pelo menos 30 valores observados no treino. Caso contrário ou com idade indisponível, vale a mediana global. O indicador de imputação numérica conserva informação sobre indisponibilidade e o ensaio de máscaras investiga seu poder preditivo. SEXO usa codificação *one-hot* com vocabulário do treino. Para a logística comparamos padronização das medidas originais com a padronização após aplicar $\log(1 + \text{Peso})$ ao Peso. As árvores usam as unidades originais. Indicadores binários permanecem em sua escala. Nenhum parâmetro de transformação é estimado nas linhas de validação.

B. Mineração e avaliação

O cenário FISIO8 usa Peso, Altura, IMC, IDADE, pressões sistólica e diastólica, FC e SEXO. STRICT4 usa Peso, Altura, IDADE e SEXO. A segunda análise reduz a dependência de medidas cardiovasculares cuja relação com a rotulagem é incerta e elimina a redundância de IMC com os insumos antropométricos. Os dois cenários compartilham os mesmos registros e cortes externos.

Usamos a classe majoritária como referência, uma árvore rasa como comparação interpretável, regressão logística regularizada e floresta aleatória [5], [6]. A grade por cenário inclui 105 configurações. São 48 de árvore (critério, profundidade, tamanho mínimo de folha, pesos e imputação), 32 de logística (regularização, representação, pesos e imputação), 24 de floresta (profundidade, folha mínima, pesos e imputação, com 150 árvores) e uma referência majoritária. Os pesos balanceados aumentam a contribuição da classe menos frequente no treino. A busca compara seu efeito com pesos uniformes. O limiar de 0,5 é fixado para a comparação.

A validação cruzada aninhada separa ajuste e estimativa de desempenho [7]. Em cada um dos cinco folds externos, três folds internos escolhem uma configuração por família pela média da acurácia balanceada (BA). Em empate numérico, prevalece a ordem fixa da grade. O procedimento reajusta o vencedor no treino externo e gera uma previsão para cada linha de sua validação. A estratificação procura preservar as proporções de classe e o agrupamento evita separar componentes candidatos entre treino e validação. Usamos `random_state=42` nos estimadores estocásticos, semente 743 nos cortes externos e $811 + k$ no corte interno do fold k, com $k = 0, \ldots, 4$.

A BA é a média da sensibilidade (fração de *Anormal* recuperada) e da especificidade (fração de *Normal* reconhecida). Ela dá o mesmo peso às classes. Relatamos também precisão da classe positiva, F_1, precisão média (AP) e matriz de confusão. As métricas principais reúnem as previsões externas de todos os folds. O desvio-padrão entre folds descreve a variação observada. Como os treinos se sobrepõem, esse desvio não foi usado como erro-padrão de observações independentes.

IV. RESULTADOS E DISCUSSÃO

A Tabela II mostra que a floresta obteve a maior BA observada em FISIO8. Seu desvio-padrão de BA entre folds foi 1,68 ponto percentual, ante 1,27 da logística e 0,40 da

Tabela II
RESULTADOS EXTERNOS AGRUPADOS POR CENÁRIO E FAMÍLIA

Cenário	Família	BA	Sens.	Prec.	F_1
FISIO8	Maioria	50,00	0,00	0,00	0,00
	Árvore	60,91	54,32	55,14	54,73
	Logística	61,64	55,51	55,89	55,70
	Floresta	**62,87**	59,29	56,51	57,87
STRICT4	Maioria	50,00	0,00	0,00	0,00
	Árvore	59,32	35,82	60,52	45,00
	Logística	**59,74**	52,03	54,03	53,01
	Floresta	59,48	48,68	54,64	51,49

Valores em porcentagem. Para a referência, precisão e F_1 são registrados como zero pela convenção de avaliação na ausência de predições positivas.

Tabela III
MATRIZES DE CONFUSÃO EXTERNAS EM FISIO8

	Logística		Floresta	
Rótulo	Normal	Anormal	Normal	Anormal
Normal	3.656	1.738	3.584	1.810
Anormal	1.765	2.202	1.615	2.352

As linhas indicam o rótulo registrado. Em cada família, as colunas indicam a classe prevista.

árvore. A AP foi 59,55% para a floresta, 56,67% para a logística e 56,00% para a árvore, frente a 42,38% na referência majoritária. Essa referência acertaria 57,62% dos rótulos com a classe *Normal* sempre e recuperaria zero positivos. A BA explicita esse desequilíbrio.

A diferença entre floresta e logística em FISIO8 foi de 1,23 ponto percentual em BA. A Tabela III mostra a troca no limiar avaliado. A floresta recuperou mais 150 registros *Anormal* e produziu mais 72 falsos positivos. Ainda deixou 1.615 positivos com previsão *Normal*, cerca de 41% dos positivos observados. Em STRICT4, a logística teve a maior BA e a floresta teve maior AP (57,43% ante 55,78%). A ordem depende da métrica e da disponibilidade dos preditores. As diferenças são descritivas e o estudo carece de uma coorte independente para confirmar sua magnitude.

A. Importância e controles

Permutamos cada variável de origem três vezes por fold externo, aplicando novamente as transformações ajustadas no treino. Na floresta em FISIO8, as maiores quedas médias de BA foram de 4,81 pontos percentuais para FC, 2,56 para Peso e 0,86 para IDADE. O resultado inclui o efeito da variável na imputação e nos indicadores derivados. Também pode depender da redundância entre Peso, Altura e IMC e de combinações pouco realistas geradas pela permutação. A medida descreve dependência preditiva do procedimento.

Uma árvore fixa com apenas máscaras de disponibilidade atingiu BA de 56,11% em FISIO8 e 50,97% em STRICT4, sinal de que o processo de coleta pode carregar informação sobre o rótulo. Com rótulos embaralhados, uma árvore rasa obteve 49,65% e 49,38%, respectivamente. Esse controle examina o comportamento esperado ao romper a relação entre entradas e rótulo. A verificação da cronologia e do critério clínico exige documentação da coleta e da rotulagem.

Em uma busca separada de cinco folds no desenvolvimento, a floresta selecionada para FISIO8 usou 150 árvores, profundidade máxima 8, 10 registros mínimos por folha, pesos balanceados e mediana global. Essa busca prepara o reajuste em todos os registros de desenvolvimento. A Tabela II estima o desempenho do procedimento por família com seleção interna, que pode escolher configurações distintas em cada fold. A exploração anterior da coorte também orientou escolhas de curadoria. A avaliação permanece interna e condicionada a essas decisões.

V. CONCLUSÃO

Após revisar a proveniência das entradas, a floresta alcançou 62,87% de BA na comparação interna do cenário fisiológico. Com as entradas antropométricas e demográficas, a logística alcançou 59,74% e liderou nessa métrica. A diferença entre cenários e o número de falsos negativos delimitam a utilidade do resultado. O trabalho sustenta uma comparação acadêmica de classificadores para o rótulo registrado. Uma avaliação clínica exigiria confirmar a disponibilidade temporal dos atributos, definir uma referência diagnóstica independente e testar em uma nova coorte.

DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

O Codex (OpenAI) auxiliou na revisão de código, na implementação dos ensaios de auditoria e validação, na geração de tabelas e gráficos e na redação e edição deste artigo e dos slides. As sugestões foram confrontadas com o dicionário, o material do estudo de caso, a rubrica e as saídas dos experimentos executados. As métricas apresentadas provêm das previsões e agregações registradas pelo código.

REFERÊNCIAS

[1] Instituto de Informática, Universidade Federal de Goiás, "Tema do estudo de caso," Material de Mineração de Dados, INF0414, SIGAA, 2026.

[2] ——, "Variáveis do conjunto de dados," Dicionário da base UCMF, Mineração de Dados, INF0414, SIGAA, 2026.

[3] "Guideline for diagnostic," Material complementar do estudo de caso UCMF, INF0414, SIGAA.

[4] "Explanation about the PPA variable," Material complementar do estudo de caso UCMF, INF0414, SIGAA.

[5] L. Breiman, "Random forests," *Machine Learning*, vol. 45, pp. 5–32, 2001.

[6] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: https://jmlr.org/papers/v12/pedregosa11a.html

[7] S. Varma and R. Simon, "Bias in error estimation when using cross-validation for model selection," *BMC Bioinformatics*, vol. 7, p. 91, 2006.