Classificação de registros de cardiologia pediátrica: o peso do exame físico frente às medidas

Antônio Henrique Queiroz Villar Lopes, João Vitor Fernandes Ferreira
Mateus Nery Bailão, Pedro Augusto Ferreira Matos
Instituto de Informática, Universidade Federal de Goiás (UFG)
Mineração de Dados (2026/2), Goiânia, Brasil

***Resumo*—Investigamos a classificação do rótulo *Normal/Anormal* em registros de cardiologia pediátrica da base UCMF. Definimos vazamento como o uso de informação indisponível no momento da previsão. Por isso excluímos identificadores, convênio, motivos de encaminhamento e um campo de anamnese quase vazio, e mantivemos medidas, sinais vitais, achados do exame físico e sintomas relatados. Em 9.361 registros, comparamos a classe majoritária, como baseline simples, com árvore de decisão, regressão logística e floresta aleatória, em validação cruzada aninhada estratificada e agrupada, com pré-processamento ajustado em cada treino. No cenário principal, a árvore obteve acurácia balanceada de 91,9%, sensibilidade de 87,5% e especificidade de 96,4%. As três famílias empataram porque o sopro cardíaco concentra a informação. Sem os achados de exame, o melhor resultado caiu para 62,9%. Todos os falsos negativos do cenário principal são crianças com rótulo anormal e sem sopro registrado.**

***Index Terms*—classificação, cardiologia pediátrica, validação cruzada aninhada, vazamento de informação, sopro cardíaco.**

I. Introdução

Cardiopatias em crianças, sobretudo as congênitas, costumam ser investigadas a partir de um atendimento ambulatorial com anamnese, medidas e exame físico, seguido de exames complementares quando há suspeita. A base UCMF reúne atendimentos de cardiologia pediátrica do Real Hospital Português, em Recife, e traz o rótulo *NORMAL X ANORMAL*, que o dicionário descreve como ausência ou presença de patologia cardíaca [1], [2]. Tratamos *Anormal* como classe positiva e perguntamos quanto os dados do próprio atendimento permitem antecipar esse rótulo.

A primeira etapa do trabalho (A1) cobriu o entendimento dos dados e o pré-processamento. Nesta segunda etapa completamos o processo de descoberta de conhecimento: revisamos limpeza e transformação, definimos quais atributos podem entrar no modelo, comparamos um baseline simples com três modelos e interpretamos acertos e erros. A escolha dos atributos segue um critério único: um atributo é vazamento quando não estaria disponível no momento em que a previsão seria feita, isto é, durante o atendimento e antes do laudo.

As contribuições são três. Primeiro, uma política de atributos justificada pela disponibilidade. Segundo, uma comparação com o mesmo protocolo em três conjuntos de atributos, que mostra de onde vem a informação. Terceiro, uma análise dos erros no contexto de uma triagem clínica.

Repositório público e código reprodutível: https://github.com/pedroafm06/Data-Mining.

II. Dados e análise exploratória

A. Origem e composição

A fonte tem 12.873 registros e 21 atributos [1], [2]: identificação (ID, Atendimento, DN), antropometria (Peso, Altura, IMC), IDADE, SEXO, sinais vitais (pressões sistólica e diastólica, PAS e PAD, e frequência cardíaca, FC), a classificação de pressão arterial PPA [3], achados do exame físico (SOPRO, segunda bulha B2 e PULSOS), sintomas da história da doença atual (HDA1 e HDA2), Convênio, os motivos de encaminhamento (MOTIVO1 e MOTIVO2) e o alvo. Há 1.169 registros sem rótulo, que ficam fora da classificação supervisionada. Dos 11.704 rotulados, 9.361 formam o conjunto de desenvolvimento e 2.342 formam o teste histórico, separado em uma fase anterior do projeto; 1 registro idêntico a outro do teste foi retirado do desenvolvimento. O desenvolvimento tem 5.394 registros *Normal* e 3.967 *Anormal* (42,4%), um desequilíbrio moderado (Fig. 1a).

B. Descobertas da análise exploratória

Os achados do exame físico separam as classes com nitidez (Fig. 1b). Entre os 3.483 registros com sopro sistólico, 95,8% são anormais; entre os 5.814 sem sopro, 10,1%. B2 normal tem 39,6% de anormais e B2 hiperfonética, 97,8%. Pulsos alterados também se concentram na classe anormal, mas são raros.

As crianças com rótulo anormal são mais novas (Fig. 1c): a mediana de idade é 2,7 anos contra 4,8, e 35,3% dos anormais têm menos de um ano, contra 17,2% dos normais. A FC mediana é 98 bpm nos anormais e 90 bpm nos normais, com intervalos interquartis sobrepostos (88–110 e 80–100 bpm). Como a FC de repouso cai com a idade, parte dessa diferença acompanha a idade.

A falta de dados é desigual: PAS falta em 56,0% dos registros, PPA em 82,2%, HDA1 em 27,0% e HDA2 em 96,5%, enquanto SOPRO, B2 e PULSOS faltam em menos de 1%.

C. Vazamento de informação

Consideramos vazamento todo atributo indisponível no momento da previsão ou que já contenha a conclusão diagnóstica. A Tabela I resume a decisão para os 21 atributos. MOTIVO1 e MOTIVO2 trazem textos como “cardiopatia já estabelecida” e “cardiopatia congênita”; a A1 já havia apontado esse risco, e cada um sozinho atinge acurácia balanceada (BA) de 67,3%

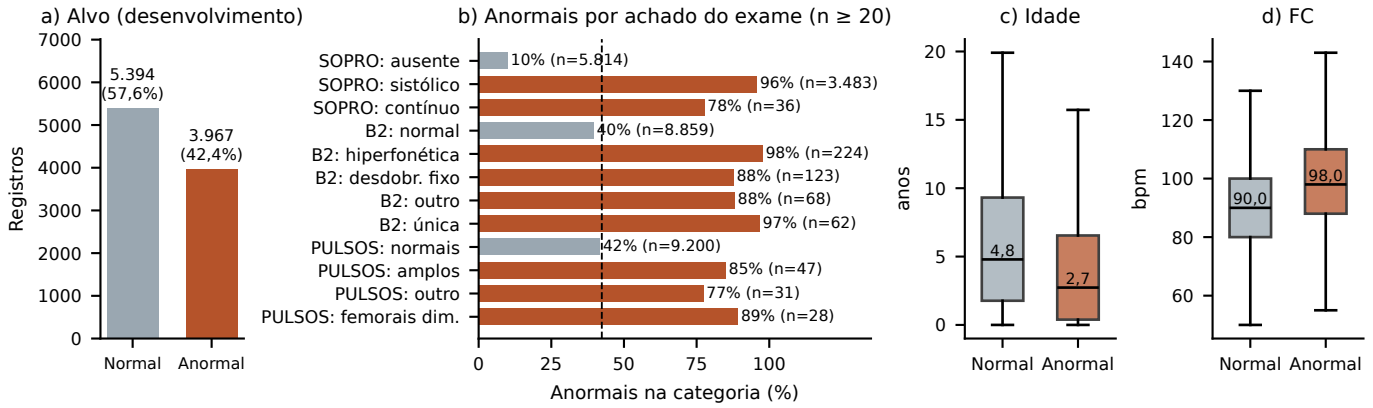


Figura 1. Conjunto de desenvolvimento. (a) Distribuição do alvo. (b) Percentual de anormais em cada categoria de SOPRO, B2 e PULSOS com pelo menos 20 registros; a linha tracejada marca a proporção geral (42,4%). (c, d) Idade e frequência cardíaca por classe; as caixas vão do primeiro ao terceiro quartil, o traço é a mediana e os pontos atípicos não são desenhados.

Tabela I
DECISÃO SOBRE OS 21 ATRIBUTOS ORIGINAIS

Atributos	Decisão
NORMAL X ANORMAL	Alvo.
ID	Fora: identificador.
Atendimento, DN	Fora como datas; usadas para conferir IDADE.
Convênio	Fora: origem do paciente, não achado clínico.
MOTIVO1, MOTIVO2	Fora: conteúdo diagnóstico explícito.
HDA2	Fora: mais de 50% de ausentes.
SOPRO, B2, PULSOS, HDA1, PPA	Em CLINICO: coletados antes do laudo.
IMC, PAS, PAD, FC	Em CLINICO e FISIO8.
Peso, Altura, IDADE, SEXO	Nos três cenários.

e 68,7% em um teste exploratório com uma árvore rasa. Convênio descreve a origem do paciente e o caminho de encaminhamento, não a criança: os 60 registros do SUS no desenvolvimento têm 95,0% de anormais, o que reflete quem encaminha, e não o que se observa no atendimento. HDA2 tem 96,5% de ausentes e sai pela regra da A1 de excluir atributos com mais de 50% de ausência.

Os achados de exame (SOPRO, B2, PULSOS), os sintomas relatados (HDA1) e a PPA, calculada a partir de PAS, PAD, idade, sexo e altura [3], são coletados durante o atendimento, antes do laudo. São exatamente a informação que o cardiologista usa para decidir a investigação [4]. SOPRO sozinho atinge BA de 91,1% no mesmo teste exploratório; isso mede poder preditivo de um dado disponível, não vazamento. O cenário principal, CLINICO, mantém esses atributos. Os cenários FISIO8 e STRICT4 servem de análise de sensibilidade: retiram os achados de exame e, no segundo caso, também os sinais vitais.

III. METODOLOGIA

A. Da A1 para a A2

A A1 removeu 987 registros iguais a outro em tudo menos no ID e chegou a 11.469 registros rotulados. Desses duplicados, 752 não tinham rótulo e 235 tinham; por isso a A2 parte de $11.704 = 11.469 + 235$ rotulados. Em vez de apagar as cópias, a A2 as mantém e controla a dependência por grupos: registros com os mesmos valores preparados e pelo menos oito campos preenchidos formam um grupo, e um grupo nunca é dividido entre treino e validação. Dos 235 duplicados rotulados (190 no desenvolvimento e 45 no teste), 93 ficam no grupo da sua cópia. Os outros 142 têm menos de oito campos preenchidos depois da limpeza (linhas quase vazias, com peso e altura zerados) e não formam grupo; 36 deles estão numa partição diferente da cópia. O desenvolvimento tem 9.279 grupos.

Três transformações planejadas na A1 mudaram. A IDADE passou a ser contínua, em vez de discretizada em quatro faixas, porque as árvores escolhem seus próprios cortes e as faixas fixas perdiam resolução no primeiro ano de vida, onde se concentram os anormais. O SEXO passou de *Binary Encoding* para *one-hot*: com três categorias (M, F e ausente), o *Binary Encoding* faz categorias distintas compartilharem bits, enquanto o *one-hot* dá uma coluna a cada uma com custo semelhante. A imputação por mediana da faixa etária deixou de ser regra fixa e virou opção da busca, comparada com a mediana global na validação interna, pois sua vantagem não estava demonstrada.

B. Limpeza e transformação

A fonte foi preservada. Padronizamos grafias, separadores decimais e códigos de ausência. Valores implausíveis, como peso ou altura zero e pressão sistólica menor ou igual à diastólica, viram ausentes com registro da regra, sem descartar a linha. IMC é recalculado de peso e altura válidos, e IDADE vem da diferença entre nascimento e atendimento quando as datas são coerentes.

Todo parâmetro aprendido dos dados é estimado só no treino de cada partição: medianas de imputação (global ou por faixa etária, com pelo menos 30 valores na faixa), médias e desvios da padronização e o vocabulário dos atributos categóricos. Cada numérico imputado ganha um indicador

binário de ausência. Os categóricos usam *one-hot* com o vocabulário do treino, uma coluna para ausente e uma coluna "desconhecido" para categorias que não apareceram no treino. A logística recebe numéricos padronizados, com a opção de aplicar $\log(1 + \text{Peso})$; árvores e floresta usam as unidades originais.

C. Cenários e algoritmos

CLINICO usa 13 atributos: Peso, Altura, IMC, IDADE, SEXO, PAS, PAD, FC, PPA, SOPRO, B2, PULSOS e HDA1. FISIO8 usa os oito primeiros (sem exame físico, anamnese e PPA), e STRICT4 usa Peso, Altura, IDADE e SEXO. Os três cenários compartilham registros e partições.

O baseline simples é a classe majoritária, que sempre prevê *Normal*. Os modelos comparados são uma árvore de decisão, a regressão logística regularizada e a floresta aleatória [5], [6]. A busca tem 105 configurações por cenário: 48 de árvore (critério, profundidade, folha mínima, pesos de classe e imputação), 32 de logística (regularização, pesos, imputação e representação), 24 de floresta com 150 árvores (profundidade, folha mínima, pesos e imputação) e o baseline. O limiar de decisão é fixo em 0,5. A implementação usa Python com pandas, NumPy, scikit-learn e matplotlib [6]–[9].

D. Validação e métricas

Usamos validação cruzada aninhada [10], estratificada pela classe e agrupada pelos grupos descritos acima. Em cada um dos cinco *folds* externos, três *folds* internos escolhem uma configuração por família pela maior BA média; o vencedor é reajustado no treino externo e prevê o *fold* externo. Assim, cada registro recebe uma previsão de um modelo que não o viu nem no ajuste nem na escolha de hiperparâmetros. As sementes são `random_state=42` nos estimadores, 743 nos *folds* externos e $811+k$ nos internos do *fold* k. O modelo final de cada família é escolhido por uma validação de cinco *folds* (semente 43) no desenvolvimento inteiro e reajustado nele.

A BA, média de sensibilidade e especificidade, é a métrica principal, porque dá o mesmo peso às duas classes. Relatamos também precisão, F_1, ROC-AUC, precisão média (AP) e matriz de confusão, sempre sobre as previsões externas agregadas. A importância de cada atributo é a queda de BA quando seus valores são embaralhados no *fold* externo, com três repetições por *fold*. O teste histórico foi examinado em fases anteriores do projeto e não participa de nenhuma escolha; aplicamos a ele os modelos finais uma única vez, como avaliação secundária.

IV. RESULTADOS E DISCUSSÃO

A. Comparação entre cenários e famílias

A Tabela II reúne as previsões externas dos 9.361 registros de desenvolvimento. Em CLINICO, árvore, logística e floresta ficam a 0,04 ponto percentual uma da outra em BA, um empate prático. Pelo critério fixado antes da execução, a árvore tem a maior BA (91,9%), com sensibilidade de 87,5% e especificidade de 96,4%. A floresta ordena melhor as probabilidades (ROC-AUC de 94,7% contra 92,3% da árvore), o que importa se o limiar for ajustado. O modelo final da árvore usa critério gini, profundidade máxima 2, 50 registros por folha, pesos uniformes e mediana global; com profundidade dois, ele equivale a uma regra sobre poucos atributos.

Tabela II
MÉTRICAS DAS PREVISÕES EXTERNAS DA VALIDAÇÃO ANINHADA (%)

Cenário	Família	BA	Sens.	Esp.	Prec.	F_1	AUC	AP
CLINICO	Maioria	50,00	0,00	100,00	0,00	0,00	50,00	42,38
	Árvore	**91,94**	87,50	96,38	94,68	90,95	92,29	91,38
	Logística	91,90	87,40	96,40	94,70	90,90	94,02	93,70
	Floresta	91,91	87,37	96,46	94,78	90,92	94,74	94,43
FISIO8	Maioria	50,00	0,00	100,00	0,00	0,00	50,00	42,38
	Árvore	60,91	54,32	67,50	55,14	54,73	63,68	56,00
	Logística	61,64	55,51	67,78	55,89	55,70	65,64	56,67
	Floresta	**62,91**	58,91	66,91	56,70	57,78	67,20	59,55
STRICT4	Maioria	50,00	0,00	100,00	0,00	0,00	50,00	42,38
	Árvore	59,32	35,82	82,81	60,52	45,00	61,53	54,37
	Logística	**59,74**	52,03	67,45	54,03	53,01	63,66	55,78
	Floresta	59,67	49,61	69,73	54,65	52,01	64,35	57,46

Sens. = sensibilidade; Esp. = especificidade; AUC = área sob a curva ROC. Maioria é o baseline simples. Em negrito, a maior BA de cada cenário. Precisão e F_1 da maioria valem zero porque ela não prevê positivos.

Tabela III
MATRIZES DE CONFUSÃO DAS PREVISÕES EXTERNAS

	CLINICO (árvore)		FISIO8 (floresta)	
Rótulo	Normal	Anormal	Normal	Anormal
Normal	5.199	195	3.609	1.785
Anormal	496	3.471	1.630	2.337

Linhas: rótulo registrado. Colunas: classe prevista.

Retirar os achados de exame derruba o desempenho: a melhor BA cai 29,0 pontos, para 62,9% (floresta em FISIO8). Retirar também os sinais vitais tira mais 3,2 pontos, para 59,7% (logística em STRICT4). Nos dois cenários de sensibilidade, os modelos superam o baseline, mas discriminam pouco.

B. De onde vem a informação

A Fig. 2 mostra que, em CLINICO, embaralhar SOPRO reduz a BA em 38,6 pontos e embaralhar B2, em 3,1; para os demais atributos a queda é nula, porque as árvores selecionadas só usam esses dois. O ganho de CLINICO sobre FISIO8 vem, portanto, da ausculta. Isso é coerente com o fluxograma de investigação do material complementar, que parte justamente de sopro, B2 e pulsos [4]. Sem o exame físico, a floresta de FISIO8 passa a depender da FC (4,9 pontos) e do Peso (2,5), e a logística de STRICT4, do Peso (10,5). FC e Peso variam fortemente com a idade, e os anormais são mais novos; boa parte do sinal desses atributos parece refletir a idade e o crescimento, e não um achado cardíaco. Em CLINICO, a FC perde a importância (0,0 ponto), porque o sopro já carrega a informação que ela trazia.

A diferença de idade entre as classes é compatível com o predomínio de cardiopatias congênitas, que costumam se manifestar e ser diagnosticadas nos primeiros meses de vida.

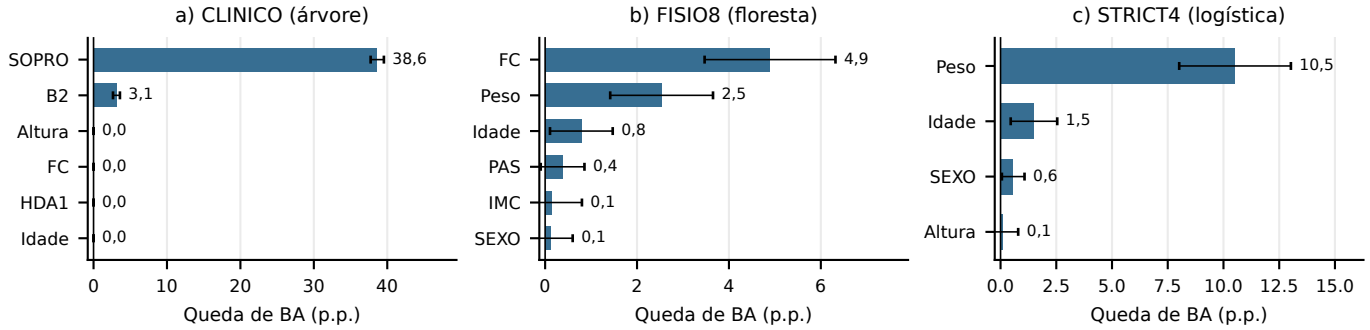


Figura 2. Importância por permutação no modelo de maior BA de cada cenário: queda média de BA ao embaralhar o atributo no *fold* externo (5 *folds* × 3 repetições; barras de erro: desvio-padrão). Seis atributos de maior queda por painel.

Tabela IV
BA NO TESTE HISTÓRICO (%), AVALIAÇÃO SECUNDÁRIA

Cenário	Árvore	Logística	Floresta
CLINICO	92,92	93,06	92,90
FISIO8	64,27	62,85	65,23
STRICT4	61,53	60,33	61,46

2.342 registros; o teste foi examinado em fases anteriores do projeto e não é intocado.

Os números descrevem associação neste serviço e não estabelecem causa.

C. Análise de erros

A Tabela III mostra que a árvore de CLINICO deixa 496 anormais como *Normal*, 12,5% dos anormais. Todos esses falsos negativos (100,0%) são registros sem sopro: o desenvolvimento tem 587 anormais sem sopro (14,8% dos anormais), e o modelo reconhece poucos deles. Já 79,0% dos 195 falsos positivos têm sopro; há 154 crianças normais com sopro, o que é compatível com sopros inocentes, frequentes na infância. Em uma triagem, os dois erros têm custos diferentes: o falso positivo leva a um exame complementar desnecessário, enquanto o falso negativo pode adiar o diagnóstico de uma cardiopatia. Por isso a sensibilidade de 87,5% é o número a melhorar, e o limiar de 0,5 não é o ponto de operação ideal para esse uso.

D. Teste histórico

Os modelos finais, aplicados uma vez aos 2.342 registros do teste histórico (Tabela IV), mantêm a ordem entre cenários: 92,9% de BA para a árvore de CLINICO, 65,2% para a floresta de FISIO8 e 60,3% para a logística de STRICT4. Os valores ficam próximos dos da validação aninhada, o que indica estabilidade dentro da mesma coorte, mas não substitui uma validação externa.

V. CONCLUSÃO E TRABALHOS FUTUROS

Com uma política de atributos baseada na disponibilidade no momento da previsão, o cenário principal alcançou BA de 91,9% na validação aninhada, e as três famílias de modelos empataram. A comparação entre cenários mostra que a informação útil está no exame físico, sobretudo no sopro: antropometria, idade e sinais vitais sozinhos levam a BA de 59,7% a 62,9%. Na prática, o modelo reproduz o raciocínio do exame cardiológico e falha justamente nas crianças com rótulo anormal e sem sopro.

Limitações. (i) O rótulo não tem padrão de referência documentado; não sabemos quem o atribuiu nem com quais exames. (ii) Supomos que achados de exame, sintomas e sinais vitais foram registrados antes do laudo; a base não traz horários que confirmem a ordem. (iii) A avaliação é interna a uma única coorte, que já havia sido explorada na A1, inclusive o teste histórico. (iv) Os grupos de registros iguais não identificam pacientes, e 36 linhas quase vazias duplicadas estão em partições diferentes. (v) A floresta aleatória mostrou pequenas variações entre sistemas operacionais com as mesmas sementes.

Trabalhos futuros. Ajustar o limiar para priorizar a sensibilidade, como pede uma triagem; estudar à parte o subgrupo de anormais sem sopro, em que idade, FC e sintomas podem ajudar; calibrar as probabilidades; e validar os modelos em outra instituição, com o critério diagnóstico documentado.

DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Quais: Claude (Anthropic), na A1 e, como Claude Code, nesta revisão final da A2; Codex (OpenAI), no desenvolvimento da A2. **Onde e para quê:** na A1, o Claude apoiou os scripts de limpeza, estatísticas e figuras, a extração das tabelas de pressão dos PDFs e a redação do relatório e dos slides. Na A2, o Codex apoiou a revisão de código, os ensaios de validação, as tabelas e gráficos e a redação do artigo e dos slides. Nesta revisão, o Claude Code implementou o cenário CLINICO, a avaliação no teste histórico, os geradores de números e figuras e a reescrita do artigo, dos slides e do README. **Como:** por conversa e execução de código no repositório, uma tarefa por vez. As decisões foram do grupo, e todos os números foram conferidos nas saídas do código, das quais este texto os importa automaticamente.

REFERÊNCIAS

[1] Instituto de Informática, Universidade Federal de Goiás, "Tema do estudo de caso," Material de Mineração de Dados, INF0414, SIGAA, 2026.

[2] ——, “Variáveis do conjunto de dados,” Dicionário da base UCMF, Mineração de Dados, INF0414, SIGAA, 2026.
[3] ——, “Explanation about the PPA variable,” Material complementar do estudo de caso UCMF, Mineração de Dados, INF0414, SIGAA, 2026.
[4] ——, “Guideline for diagnostic,” Material complementar do estudo de caso UCMF, Mineração de Dados, INF0414, SIGAA, 2026.
[5] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001.
[6] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: https://jmlr.org/papers/v12/pedregosa11a.html
[7] W. McKinney, “Data structures for statistical computing in Python,” in *Proceedings of the 9th Python in Science Conference*, 2010, pp. 56–61.
[8] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith *et al.*, “Array programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020.
[9] J. D. Hunter, “Matplotlib: A 2D graphics environment,” *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007.
[10] S. Varma and R. Simon, “Bias in error estimation when using cross-validation for model selection,” *BMC Bioinformatics*, vol. 7, p. 91, 2006.