Classificação de registros de cardiologia pediátrica

O peso do exame físico frente às medidas

Mineração de Dados
UFG, Grupo 3, 2026/2

Antônio Henrique Queiroz Villar Lopes
João Vitor Fernandes Ferreira
Mateus Nery Bailão
Pedro Augusto Ferreira Matos

Tarefa

Normal ou Anormal?

Classe positiva: Anormal

Entrada: o que se coleta no atendimento, antes do laudo

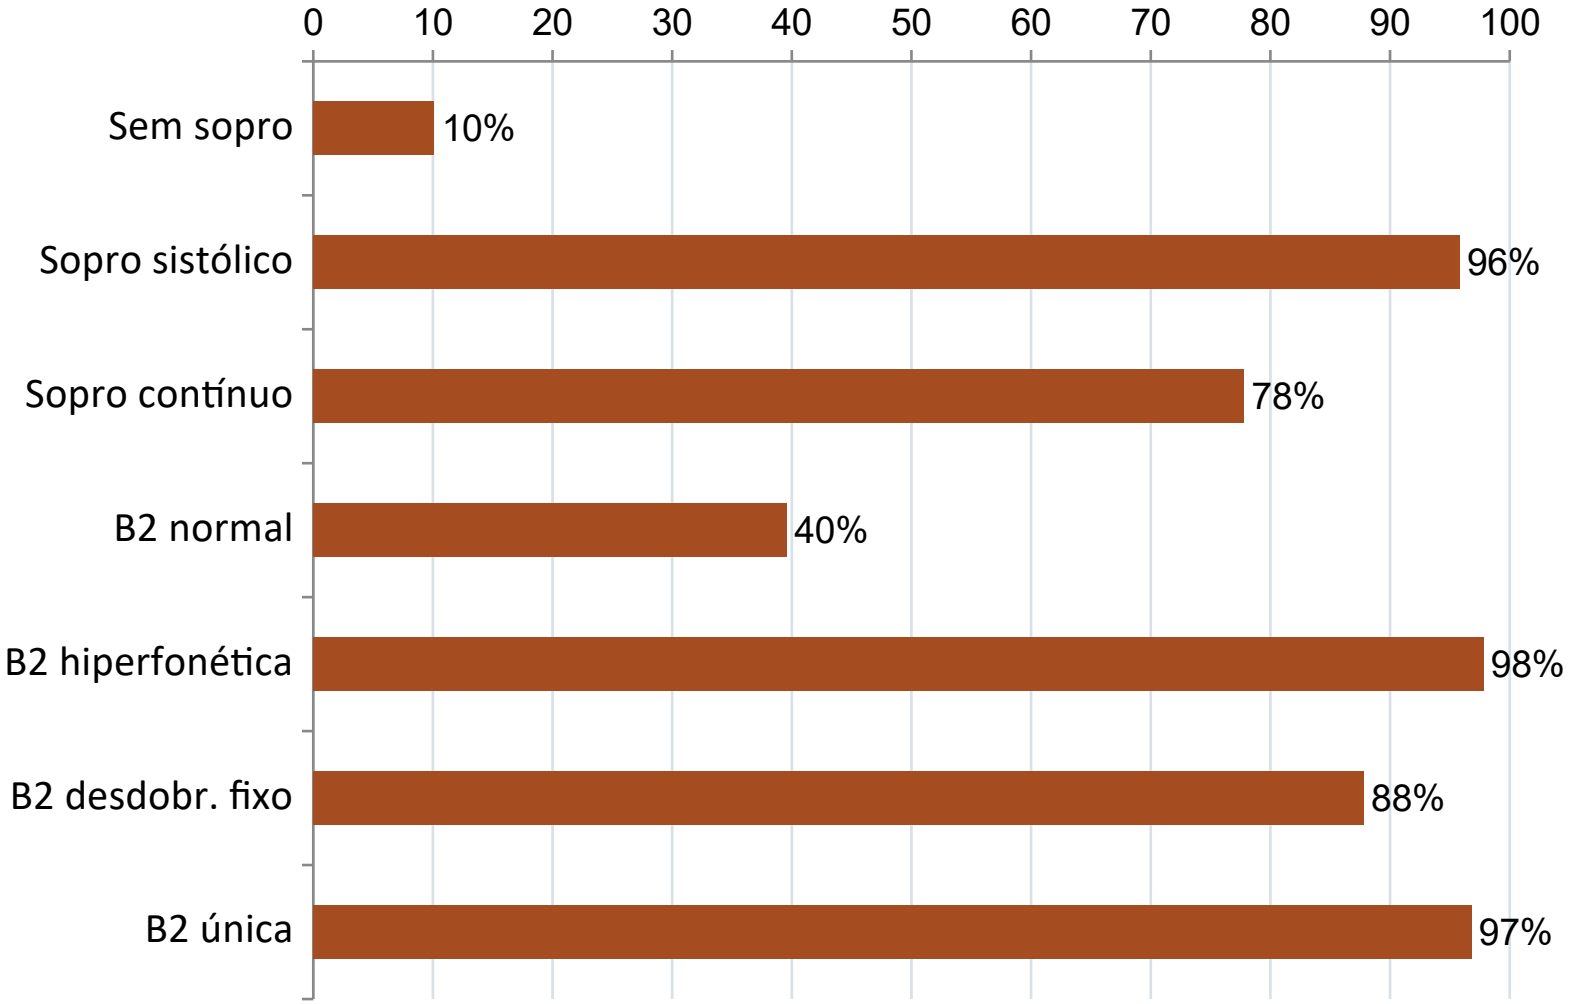
Uso pensado: apoio à triagem

Dados e partições



5.394 Normal · 3.967 Anormal (42,4%)

O exame físico separa as classes



95,8%
anormais com
sopro sistólico

10,1%
anormais
sem sopro

Idade e frequência cardíaca

Idade mediana

2,7 anos
Anormal

4,8 anos
Normal

Menos de 1 ano: 35,3% dos anormais e 17,2% dos normais

FC mediana

98 bpm
Anormal

90 bpm
Normal

A FC cai com a idade: parte da diferença é idade

Compatível com cardiopatia congênita percebida cedo

Critério de vazamento: disponível antes do laudo?

Sai

Atributo	Motivo
ID, datas brutas	Identificação
Convênio	Origem do paciente (SUS: 95,0% anormais)
MOTIVO1 e 2	Diagnóstico escrito
HDA2	96,5% ausentes

Fica

Peso, Altura, IMC, Idade, Sexo

PAS, PAD, FC e PPA

SOPRO, B2 e PULSOS

HDA1 (sintomas)

SOPRO sozinho: BA de 91,1%

poder preditivo, não vazamento

Três cenários, mesmo protocolo

CLINICO

13 atributos · principal

Medidas, idade, sexo

Sinais vitais e PPA

SOPRO, B2, PULSOS

HDA1

FISIO8

8 atributos · sensibilidade

Medidas, idade, sexo

Sinais vitais

STRICT4

4 atributos · sensibilidade

Peso, Altura

Idade, Sexo

Mesmos registros, mesmos folds, mesmas sementes

Da A1 para a A2

987 duplicados na A1 = 752 sem rótulo + 235 rotulados

A2: 11.469 + 235 = 11.704 rotulados; registros iguais ficam no mesmo grupo

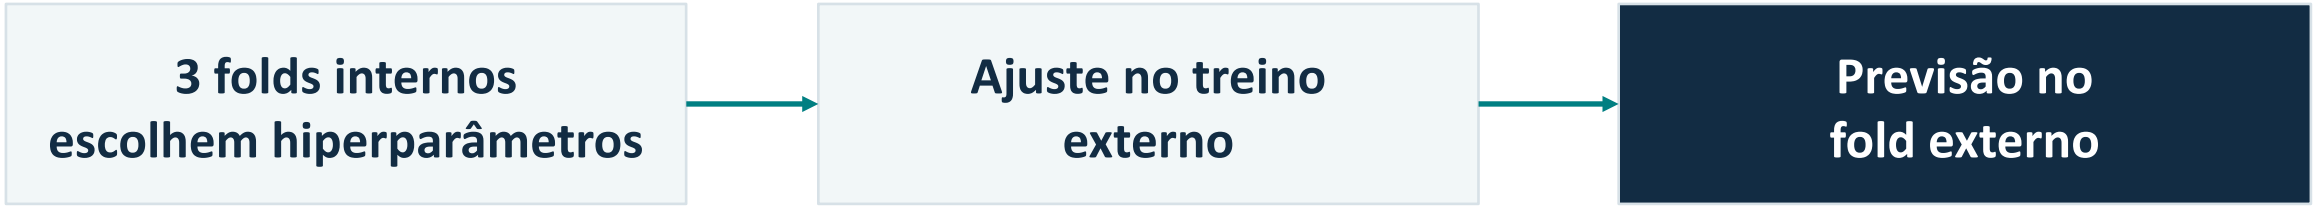
Plano da A1	Na A2	Por quê
Idade em 4 faixas	Idade contínua	Árvores escolhem os cortes
Sexo em Binary Encoding	One-hot	Uma coluna por categoria
Imputação por faixa etária	Opção testada	Escolhida na validação interna

Pré-processamento e validação aninhada



4 folds: treino externo

1 fold: avaliação



Medianas, escalas e categorias ajustadas só no treino

Estratificada e agrupada · sementes 42, 743 e 811+k

Modelos e métricas

Modelo	Papel
Classe majoritária	Baseline simples
Árvore de decisão	Modelo comparado, interpretável
Regressão logística	Modelo comparado, linear
Floresta aleatória	Modelo comparado, conjunto de árvores

105 configurações por cenário · limiar 0,5

BA = (sensibilidade + especificidade) / 2

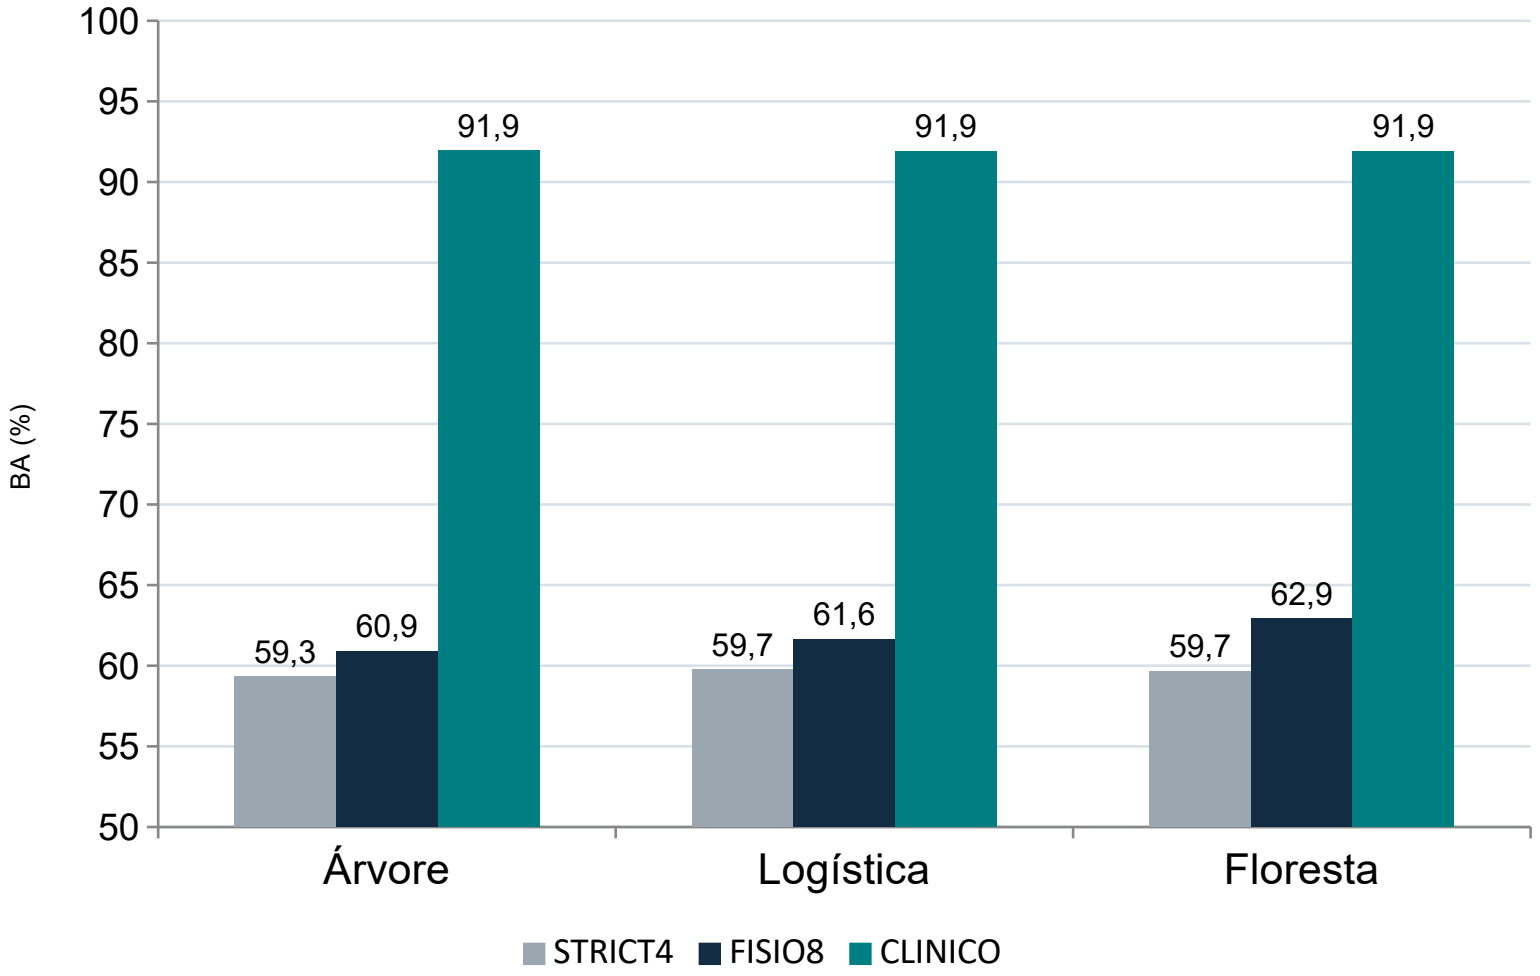
CLINICO: três modelos empatados

Modelo	BA	Sensib.	Especif.	ROC-AUC
Classe majoritária	50,0%	0,0%	100,0%	50,0%
Árvore	91,9%	87,5%	96,4%	92,3%
Logística	91,9%	87,4%	96,4%	94,0%
Floresta	91,9%	87,4%	96,5%	94,7%

Diferença entre os três: 0,04 ponto de BA

Previsões externas da validação aninhada

De onde vem a informação



–29,0 p.p.

sem o exame físico

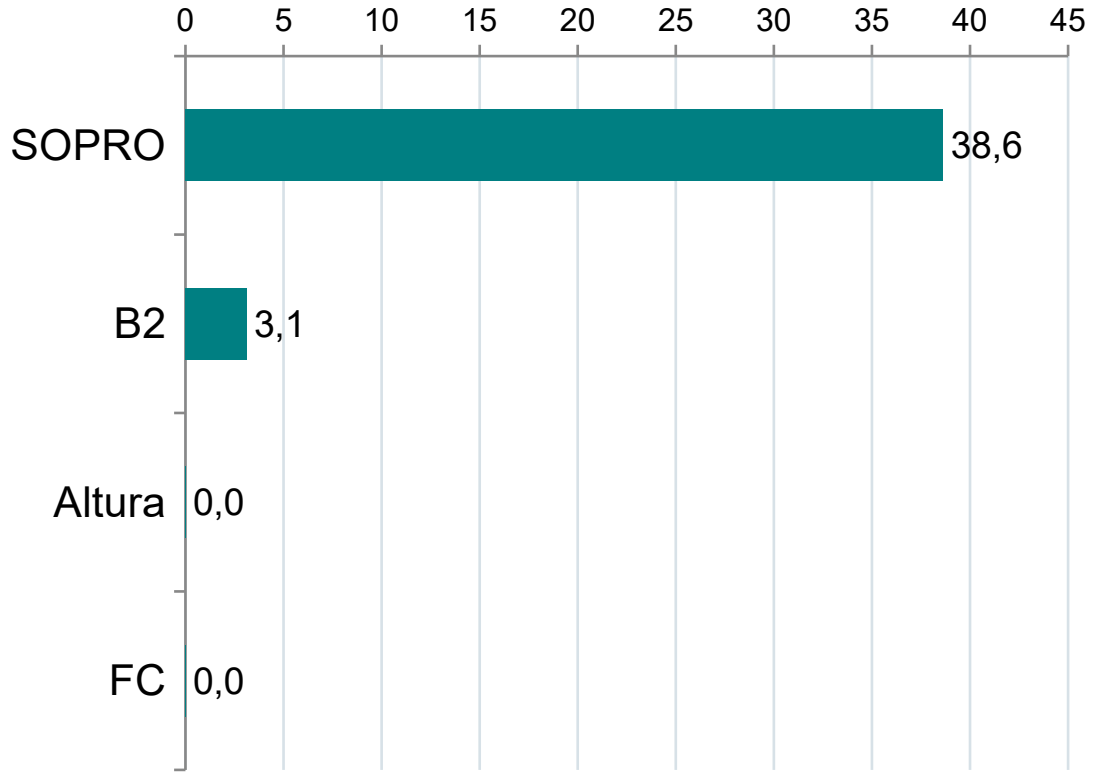
–3,2 p.p.

sem os sinais vitais

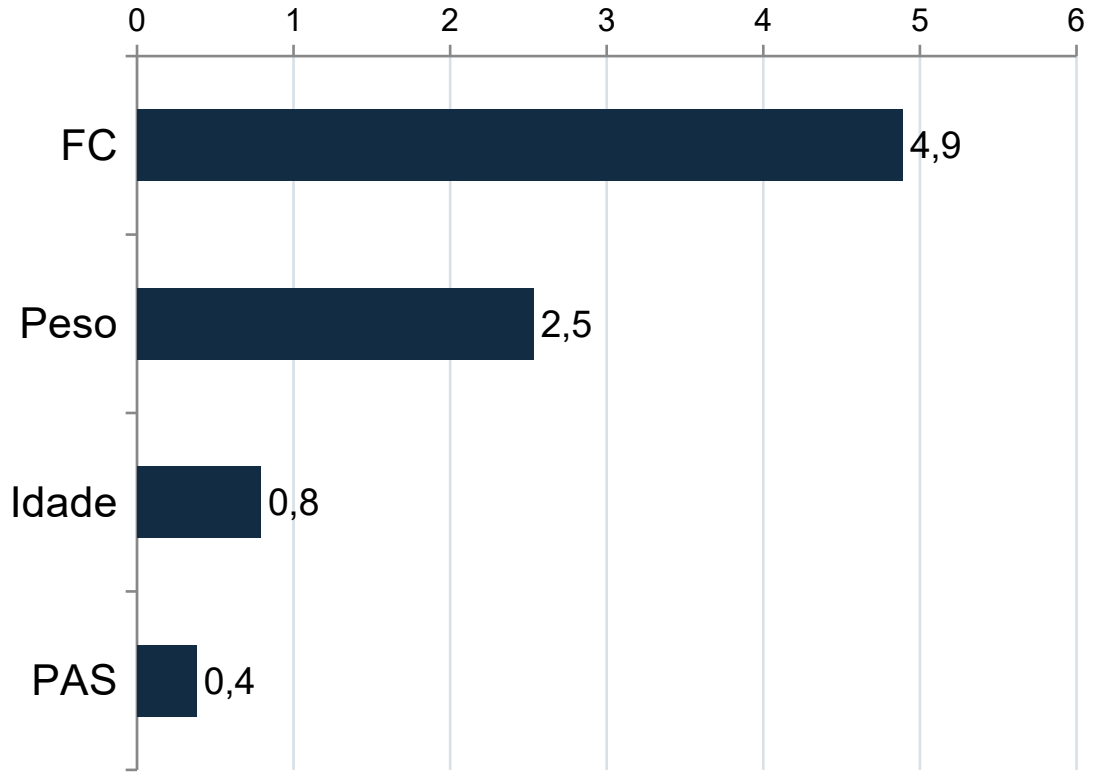
Teste histórico: 92,9% · 65,2% · 60,3%

Importância por permutação

CLINICO (árvore)



FISIO8 (floresta)



Queda de BA ao embaralhar o atributo no fold externo

Análise de erros (CLINICO, árvore)

Rótulo \ previsão	Normal	Anormal
Normal	5.199	195
Anormal	496	3.471

100,0%

dos 496 falsos negativos

não têm sopro

79,0%

dos 195 falsos positivos têm sopro

Na triagem, o falso negativo é o erro caro

Conclusão e limitações

91,9%

BA no CLINICO

a informação está na ausculta

Limitações

- Rótulo sem padrão de referência
- Ordem de registro suposta, sem horários
- Avaliação interna a uma coorte
- Grupos não identificam pacientes

Próximo passo: ajustar o limiar para a sensibilidade e estudar as crianças sem sopro