Classificação de registros cardíacos pediátricos

Auditoria de atributos e avaliação comparável

Mineração de Dados
UFG, Grupo 3, 2026/2

Antônio Henrique Queiroz Villar Lopes
João Vitor Fernandes Ferreira
Mateus Nery Bailão
Pedro Augusto Ferreira Matos

Tarefa e significado do alvo

Normal ou Anormal

Classificação supervisionada do rótulo registrado

O dicionário define presença ou ausência de patologia cardíaca.

Referência clínica, examinador e ordem de coleta desconhecidos.

A conclusão depende da disponibilidade das entradas antes do uso.

Coorte e partições



5.394 Normal e 3.967 Anormal no desenvolvimento (42,4% Anormal)

Grupos candidatos não confirmam identidade. A linha em quarentena permanece na fonte.

Campos com risco de vazamento

Informação	Evidência disponível	Decisão principal
MOTIVO1 e MOTIVO2	Conteúdo diagnóstico explícito	Excluir
SOPRO, B2 e PULSOS	Possível incorporação ao rótulo	Excluir
PPA	Classificação de hipertensão	Excluir
HDA 1 e HDA2	Sintomas, proveniência temporal incerta	Excluir

SOPRO isolado: 91,05% de BA. B2 isolado: 55,32%.

A exclusão também considera o papel de cada campo na investigação diagnóstica.

Conjuntos de atributos

FISIO8

Peso, Altura, IMC e IDADE
PAS, PAD e FC
SEXO

Cenário fisiológico

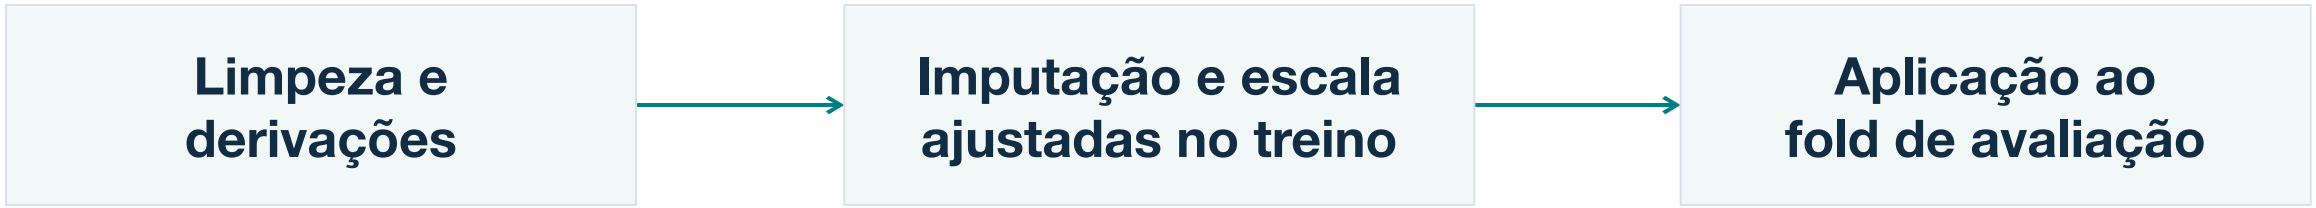
STRICT4

Peso e Altura
IDADE e SEXO

Sensibilidade mais restrita

Os dois cenários pressupõem disponibilidade das medidas antes do uso.

Pré-processamento no treino



Padronização de unidades e marcação de valores suspeitos.

Mediana global ou por idade, codificação one-hot e escala.

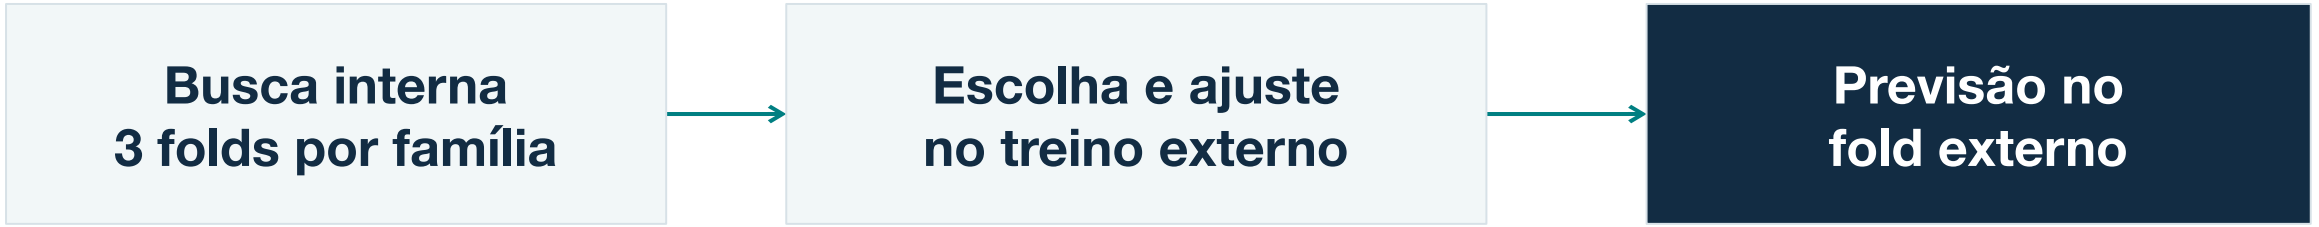
Padrões de ausência podem representar o processo de coleta.

Validação aninhada



4 folds no treino externo

1 fold para avaliar



5 repetições externas, uma previsão por registro

Mesmos folds para todas as famílias e os dois conjuntos. Grupos candidatos permanecem juntos.

Algoritmos e métricas

Família	Papel	Configurações
Referência	Classe mais frequente	1
Regressão logística	Baseline linear regularizado	32
Árvore	Regras não lineares	48
Floresta	Agregação de árvores	24

Seleção: acurácia balanceada. Limiar fixo: 0,5.

BA = média entre sensibilidade e especificidade. AUC complementa o limiar fixo.

Comparação principal em FISIO8

Modelo	BA	ROC-AUC	Sensibilidade	Especificidade
Referência	50,0%	0,500	0,0%	100,0%
Árvore	60,9%	0,637	54,3%	67,5%
Logística	61,6%	0,656	55,5%	67,8%
Floresta	62,9%	0,672	59,3%	66,4%

Maior BA observada: 62,9%

9.361 previsões externas. Comparação interna à mesma coorte, sem validação clínica independente.

Erros da floresta em FISIO8

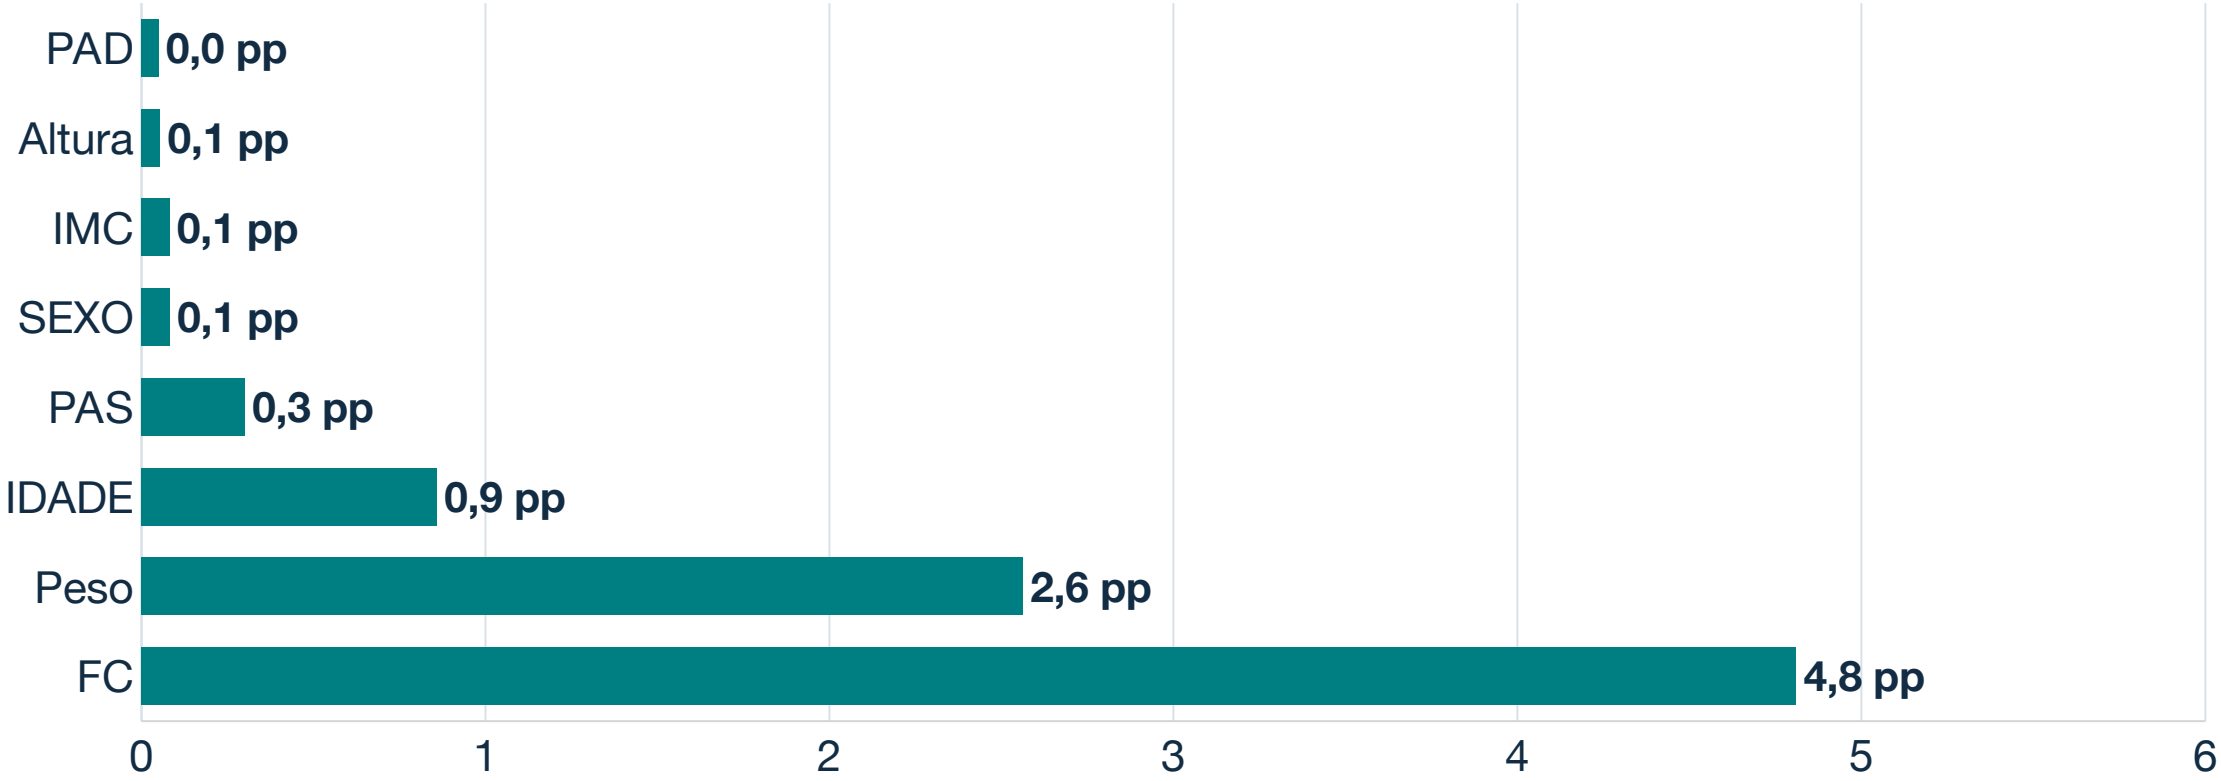
Registro / previsão	Normal	Anormal	Total
Normal	3.584	1.810	5.394
Anormal	1.615	2.352	3.967
Total	5.199	4.162	9.361

40,7%

dos Anormal recebem previsão Normal

Limiar 0,5. Cada erro é definido contra o rótulo registrado.

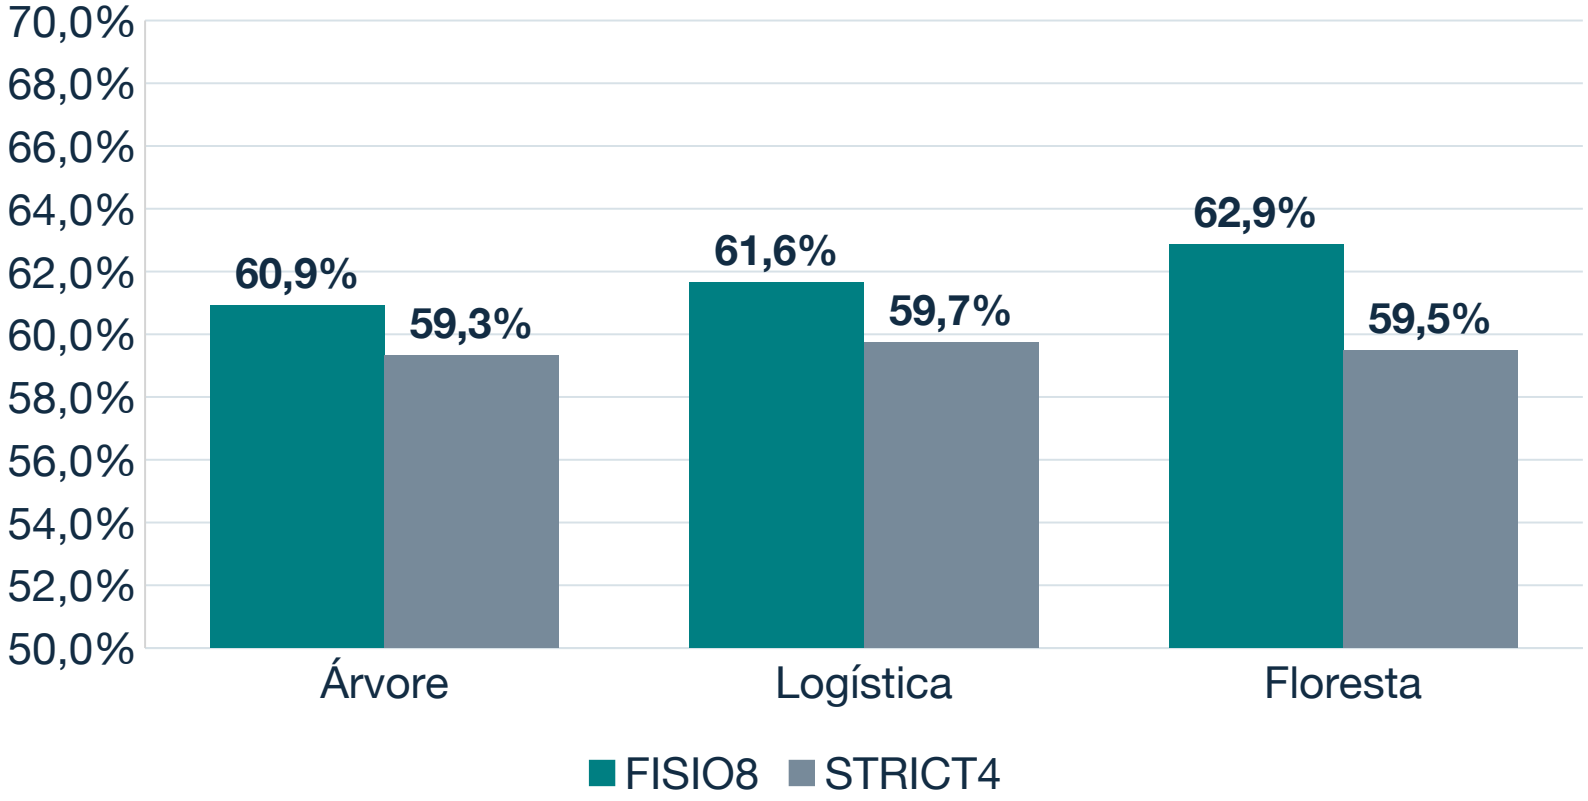
Dependência dos atributos



Permutação no fold externo, 5 folds e 3 repetições por variável.

Importância mede dependência do modelo e não demonstra causalidade ou proveniência.

Sensibilidades e processo de coleta



Somente máscaras de disponibilidade

BA 56,1%

FISIO8, árvore fixa controle exploratório

A diferença entre os conjuntos não identifica isoladamente o efeito de cada medida.

Limites da evidência

Referência do alvo e ordem de coleta desconhecidas

Grupos candidatos sem identidade de paciente confirmada

Serviço de cardiologia e seleção de registros com rótulo

Exploração histórica da coorte permanece relevante

A validação aninhada controla a busca desta execução. Ela não apaga decisões anteriores.

Conclusão

62,9%

maior BA observada
na floresta FISIO8

Discriminação limitada do rótulo registrado

Próximo avanço: esclarecer a formação do alvo e a ordem de coleta, seguido de avaliação confirmatória separada.